南京财经大学
NANJING UNIVERSITY OF FINANCE & ECONOMICS

《人工智能》研究生通识课

四、人工智能前沿技术

主讲人：朱桂祥

计算机与人工智能学院&网络与数据中心&工商管理学院
电子商务信息处理国家级国际联合研究中心
电子商务交易技术国家地方联合工程实验室
江苏省电子商务重点实验室
江苏高校重点实验室：旅游数智决策与创新管理实验室

NECC

JIANGSU PROVINCIAL KEY LAB. OF E-BUSINESS JSEB 1999

目录

1 智能决策的范式突破—深度强化学习

2 自然语言理解的里程碑— BERT

3 以规模铸就优势—大模型技术

4 全能王者—多模态大模型

5 让AI从“能说会道”到“动手干活”—龙虾OpenClaw

01

智能决策的范式突破—深度强化学习

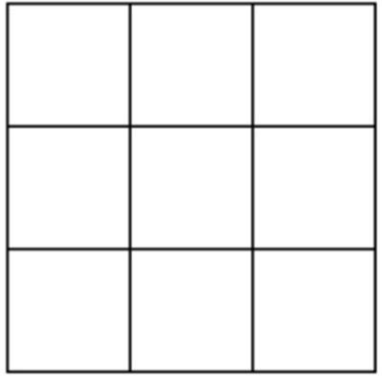
1.1 马尔科夫决策过程

- 给定当前状态，一个系统的**未来状态**只由**当前状态**和**当前行动**决定，与过去的**历史状态**无关 ⇒ **马尔可夫性质**
- 马尔可夫链：一个满足马尔可夫性质的随机过程，即给定当前状态的条件下，未来状态的概率分布仅依赖于当前状态，而与过去状态无关。

名人堂



安德雷·安德耶维齐·马尔可夫（1856年6月14日—1922年7月20日），俄国数学家，师从切比雪夫，1886年当选为圣彼得堡科学院院士。马尔可夫1922年逝世于圣彼得堡。著名的马尔可夫决策过程的得名正是为纪念他为马尔可夫链所做的研究。

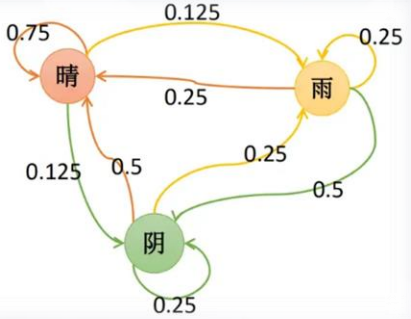


- ✓ **无记忆性**
- ✓ **状态转移过程只与当前状态和行动有关**

1.1 马尔科夫决策过程

设将天气状态分为晴、阴、雨三种状态，假定某天的天气状态只和上一天的天气状态有关，状态使用1(晴)、2(阴)、3(雨)表示，转移概率矩阵*P*如下：

今/明	晴	阴	雨
晴	0.75	0.125	0.125
阴	0.5	0.25	0.25
雨	0.25	0.5	0.25



初始概率π[0.1,0.6,0.3]

$$P=\begin{bmatrix}0.75 & 0.125 & 0.125\\ 0.5 & 0.25 & 0.25\\ 0.25 & 0.5 & 0.25\end{bmatrix}$$

第n天	晴	阴	雨
0	0.1	0.6	0.3
1	0.45	0.3125	0.2375
2	0.5531	0.2531	0.1937
3	0.5898	0.2293	0.1809
4	0.6022	0.2215	0.1763
5	0.6065	0.2188	0.1747
6	0.6079	0.2179	0.1742
7	0.6084	0.2176	0.174
8	0.6086	0.2174	0.1739
9	0.6087	0.2174	0.1739
10	0.6087	0.2174	0.1739
11	0.6087	0.2174	0.1739

1.2 强化学习

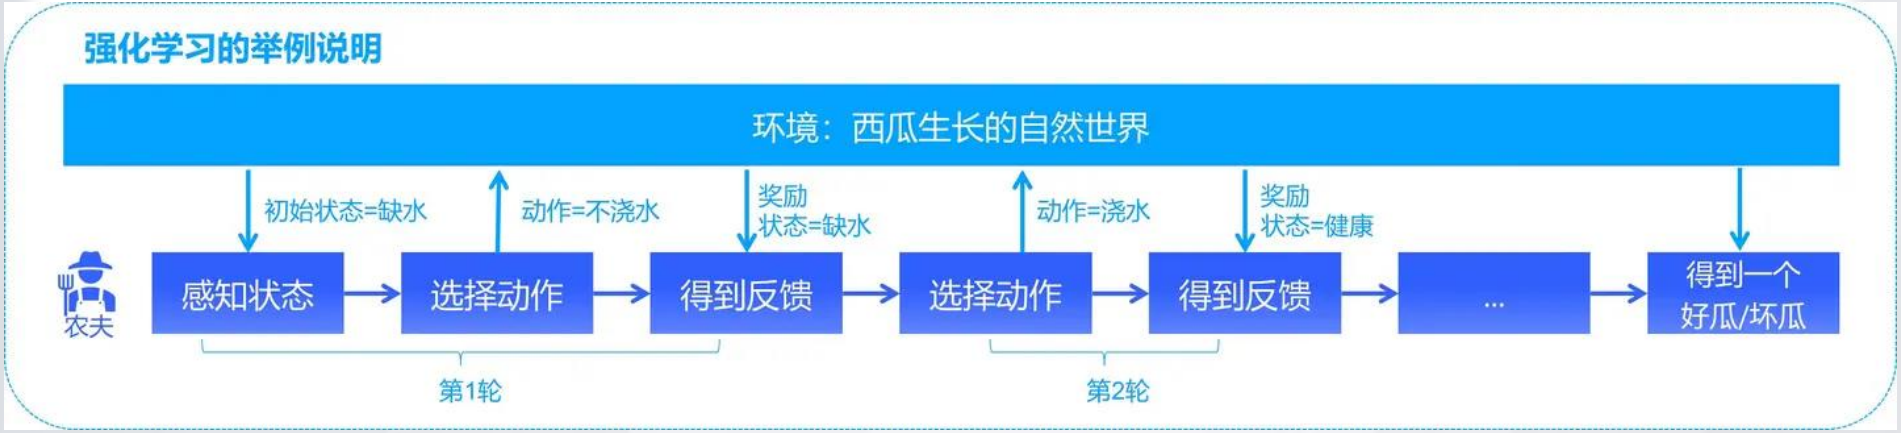
强化学习（Reinforcement Learning, RL）通过与环境进行交互，通过试错来学习，解决最优决策的问题。





1.2 强化学习

强化学习任务要求智能体在面对复杂、动态变化的环境时，**聚焦于当前的状态和决策**，**而不会过分纠结于历史经验或未来的不确定性**，然后通过迭代来寻求**长期的**最大化累积奖励。



思考： 监督学习和强化学习的区别?

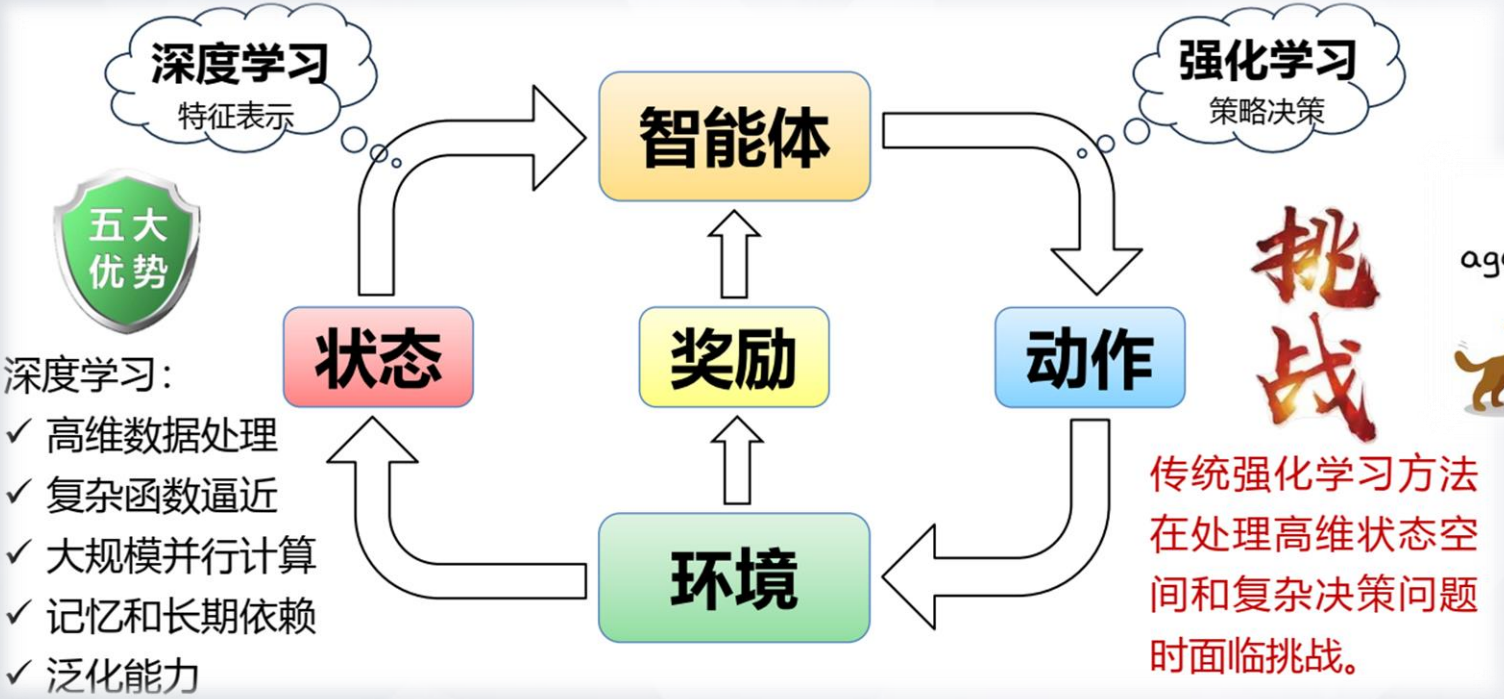


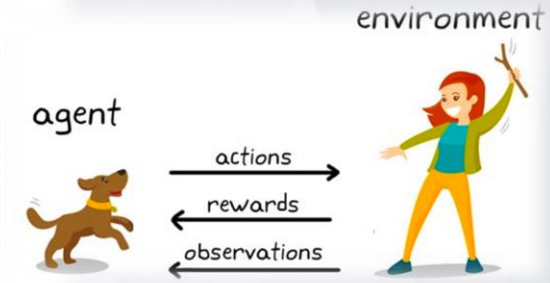
相较于有监督学习强化学习的关键区别是什么

搞AI总听人说强化学习

1.3 深度强化学习

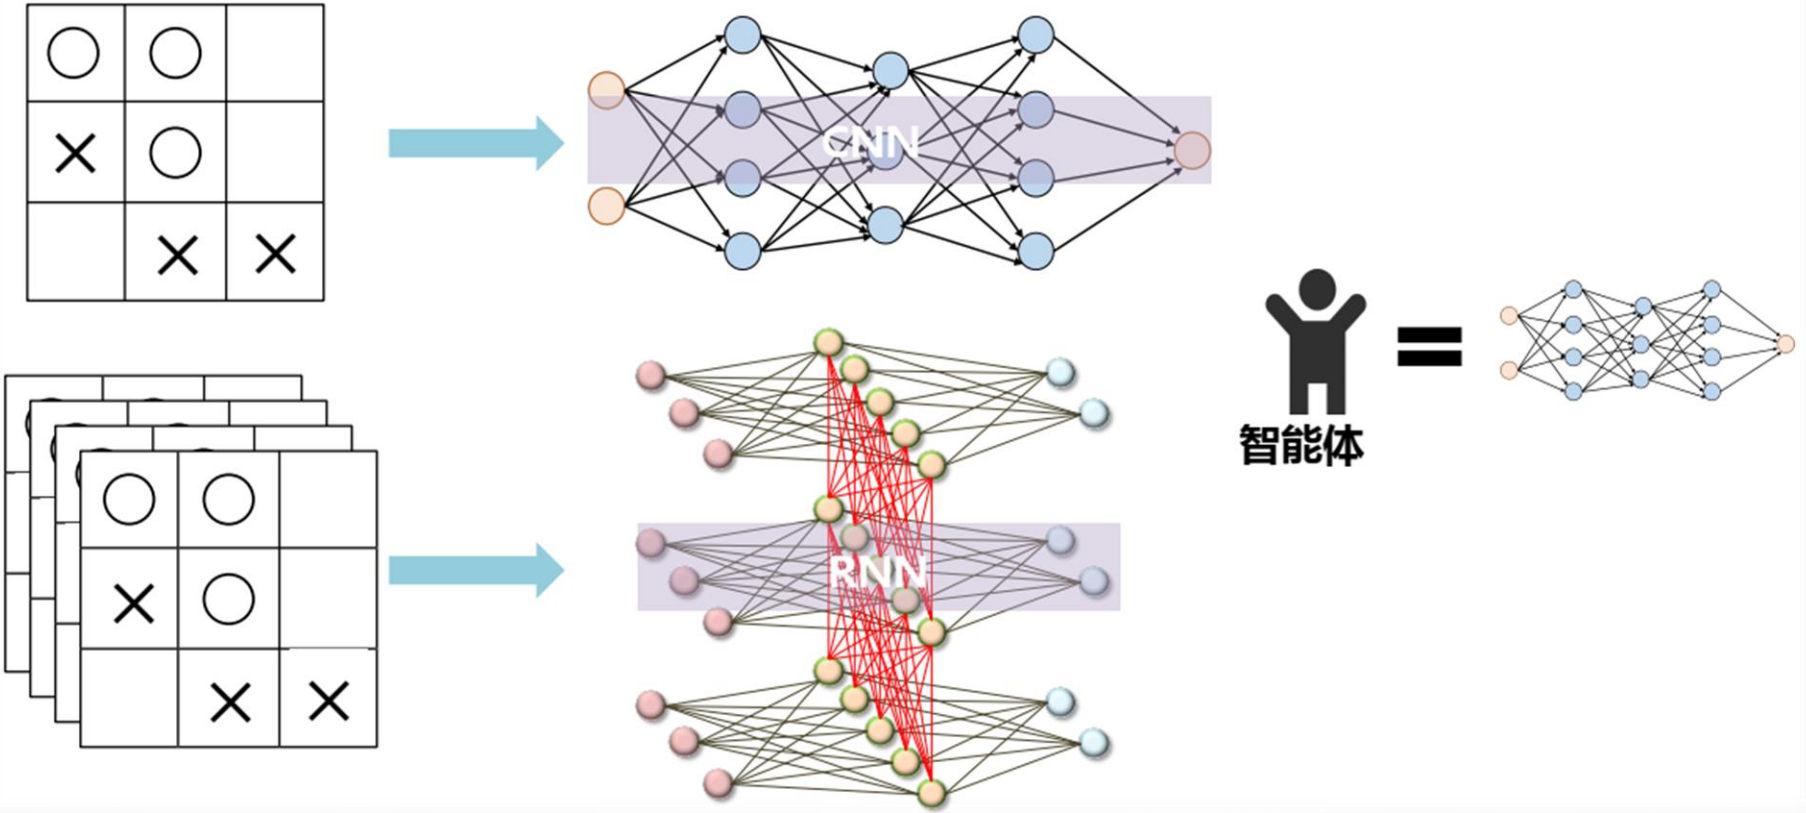
深度强化学习（Deep Reinforcement Learning，DRL）是融合深度学习感知能力与强化学习决策能力的人工智能方法，通过智能体与环境的交互实现从图像输入到动作输出的端到端控制，模拟人类决策思维方式。





1.3 深度强化学习

使用神经网络构建强化学习主体的方法被称为深度强化学习

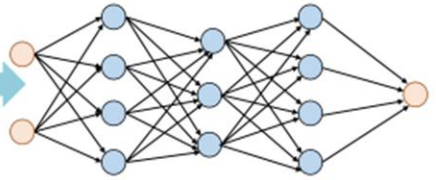


1.3 深度强化学习—基于价值的方法

Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$



DQN方法



Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$



Atari 2600游戏

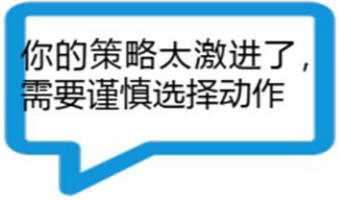
Double-DQN

Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$

价值



动作



Q-Table		
	a_1	a_2
s_1	$Q(s_1,a_1)$	$Q(s_1,a_2)$
s_2	$Q(s_2,a_1)$	$Q(s_2,a_2)$
s_3	$Q(s_3,a_1)$	$Q(s_3,a_2)$
s_4	$Q(s_4,a_1)$	$Q(s_4,a_2)$
s_5	$Q(s_5,a_1)$	$Q(s_5,a_2)$



星际争霸II

1.3 深度强化学习—基于策略的方法

策略梯度方法



策略选择动作



梯度上升

P（动作）





围棋

演员-评论家算法



Actor

选择动作



价值评估



Critic



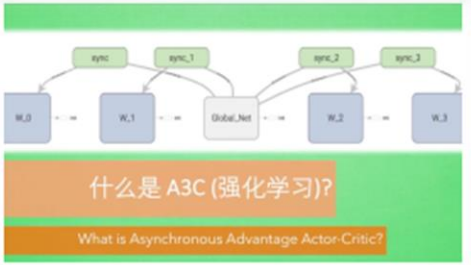
用 Critic 的反馈来优化 Actor 的策略



自动驾驶

1.3 深度强化学习—基于策略的方法

A3C方法





多个 Actor 独立与环境交互并异步更新全局网络

1.3 深度强化学习

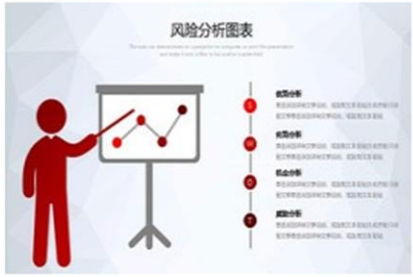


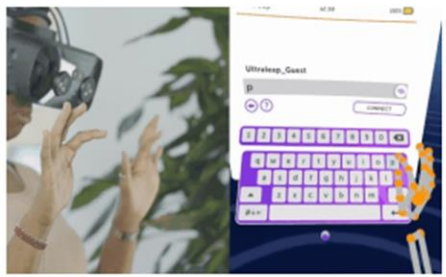




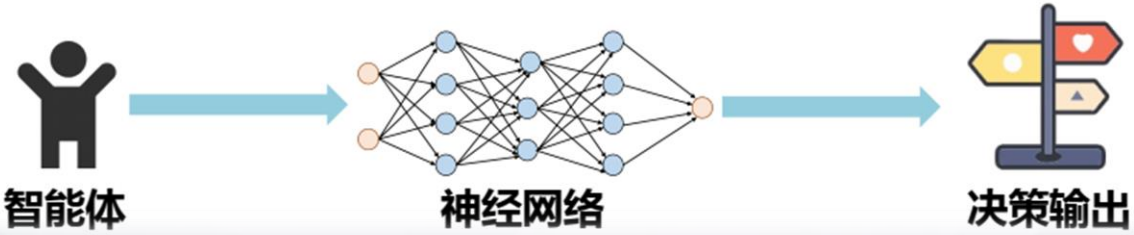












1.3 深度强化学习– DeepMindAI自主学习足球机器人



02

自然语言理解的里程碑— BERT

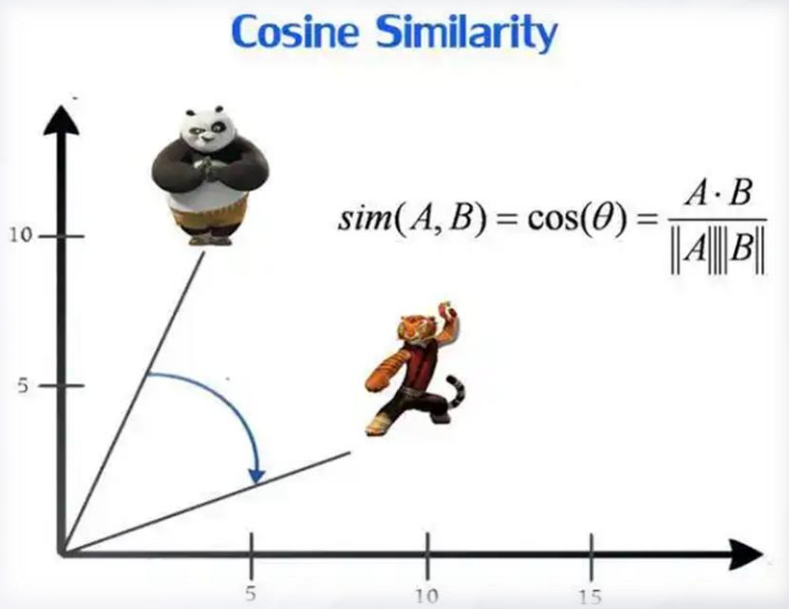
2.1 Word2Vec

Word2Vec可将“不可计算”和“非结构化”的词转化为“可计算”和“结构化”的向量

Word2Vec是google在2013年推出的一个NLP工具，它的特点是能够将单词转化为向量来表示，这样词与词之间就可以定量的去度量他们之间的关系，挖掘词之间的联系。

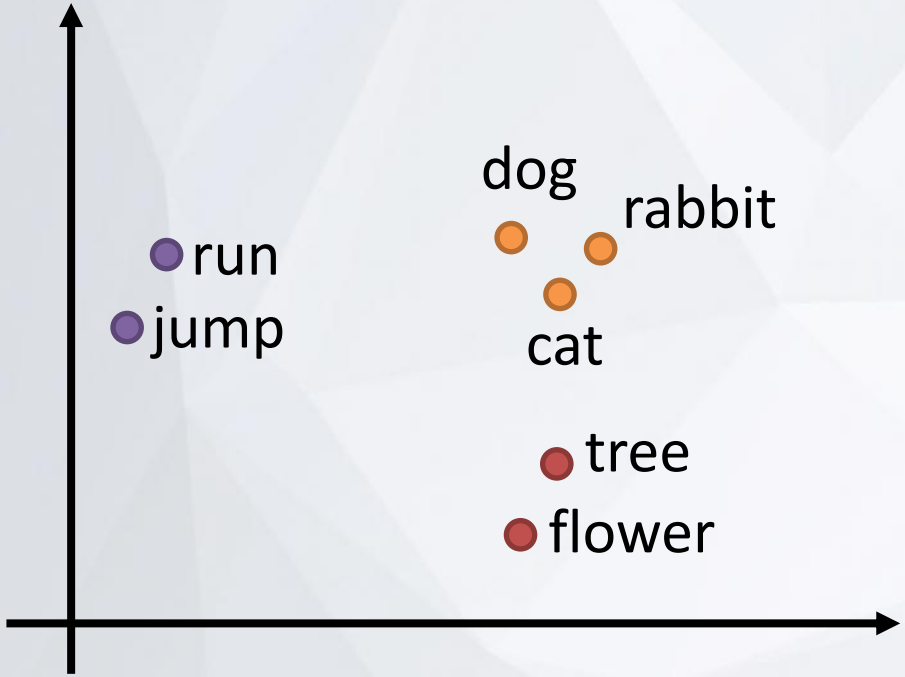


如果词的语义相近，它们的词向量在向量空间中也相互接近，这使得词语的向量化建模更加精确，可以改善现有方法并提高鲁棒性。词向量已被证明在许多自然语言处理问题，如：机器翻译，标注问题，实体识别等问题中具有非常重要的作用。

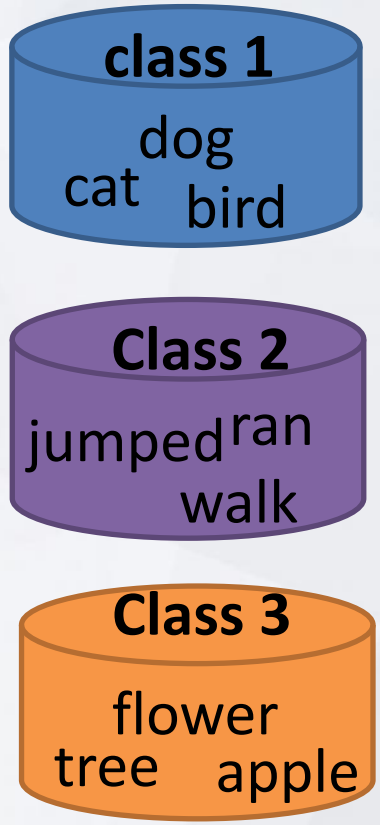


2.1 Word2Vec

Word Embedding

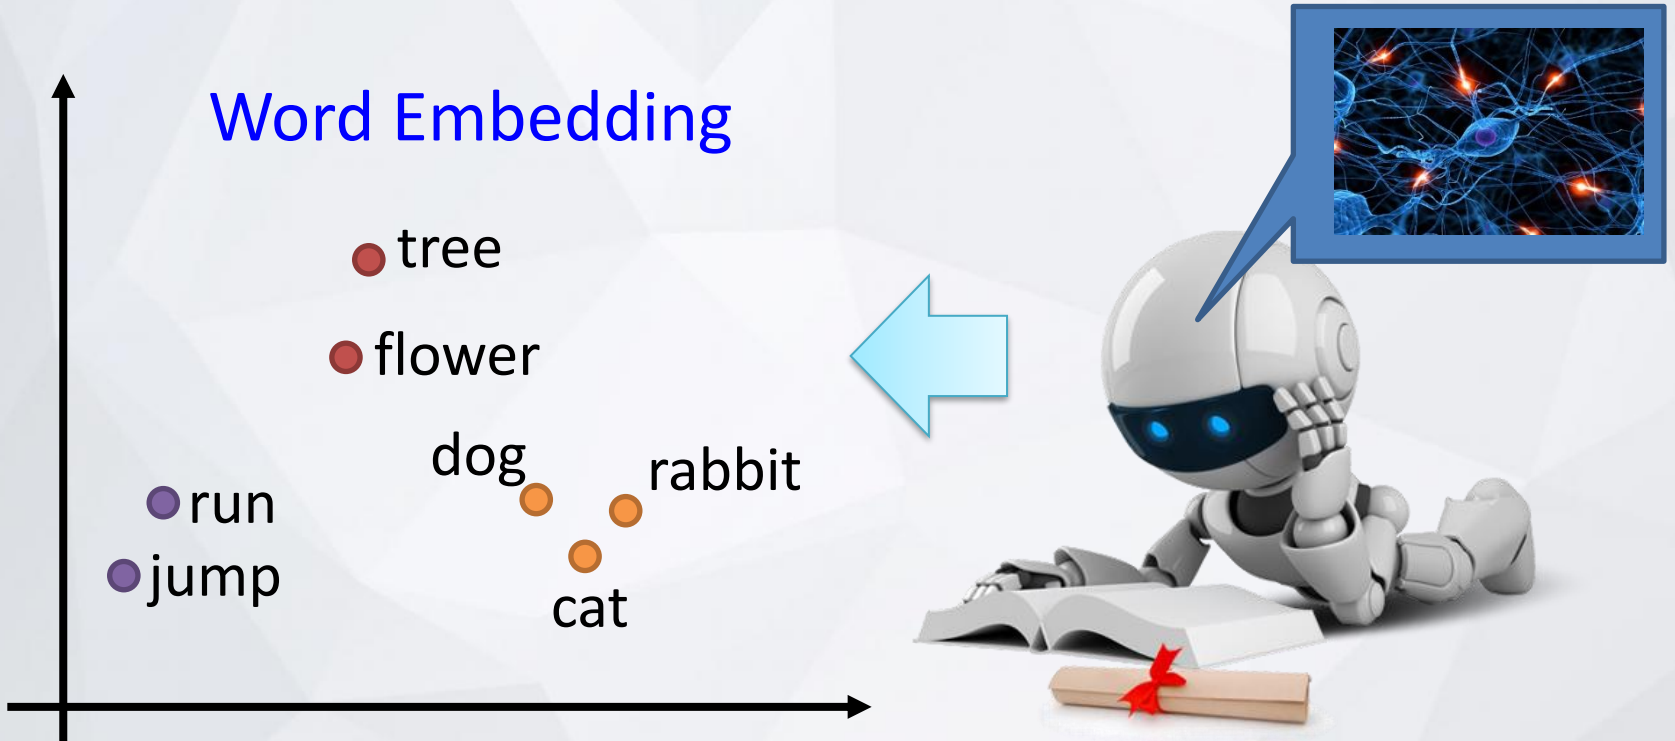


Word Class

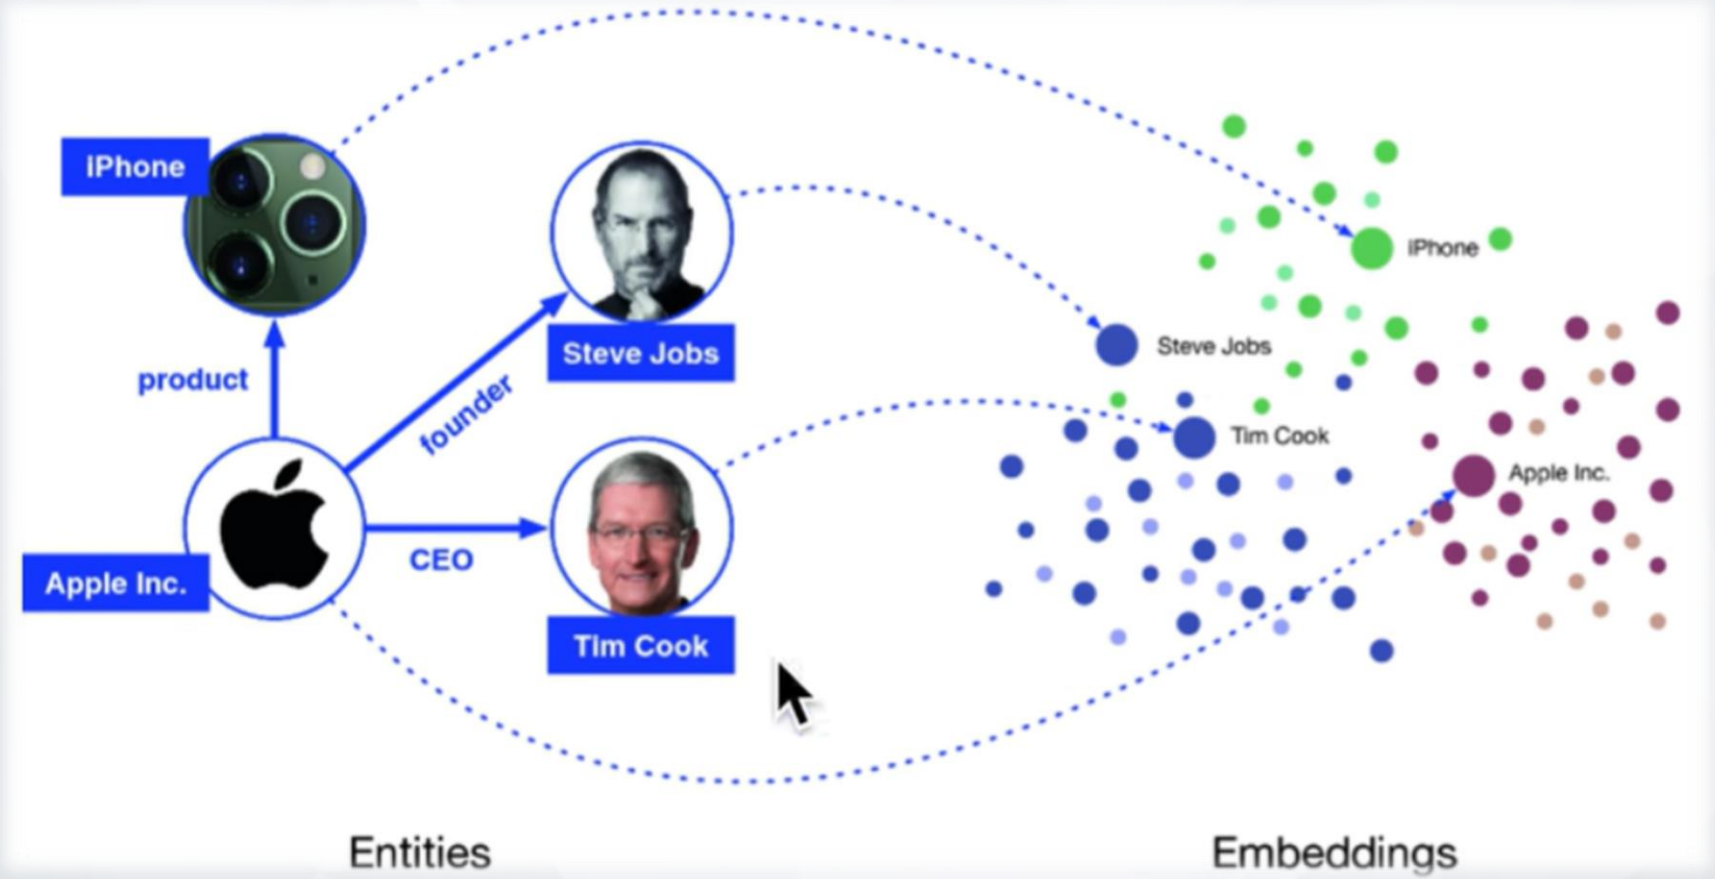


2.1 Word2Vec

- Machine learn the meaning of words from reading a lot of documents without supervision

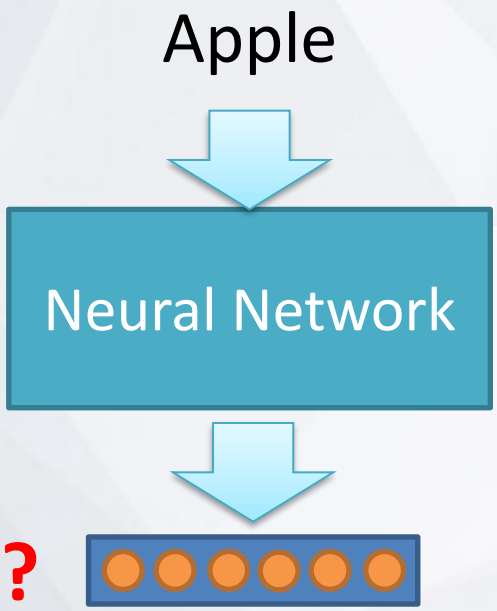


2.1 Word2Vec


iPhone
product
Steve Jobs
founder
Apple Inc.
CEO
Tim Cook
Entities
iPhone
Steve Jobs
Tim Cook
Apple Inc.
Embeddings

2.1 Word2Vec

- Generating Word Vector is unsupervised

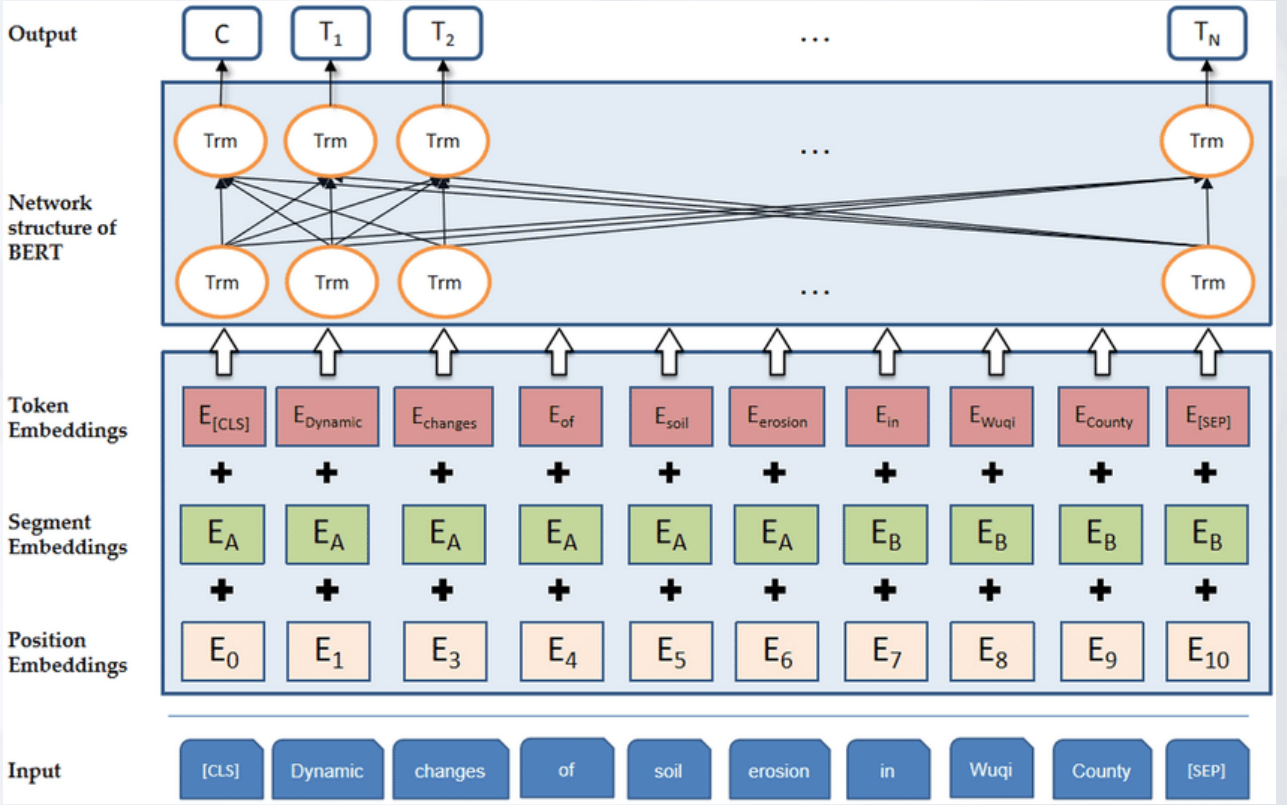


Training data is a lot of text



2.2 BERT

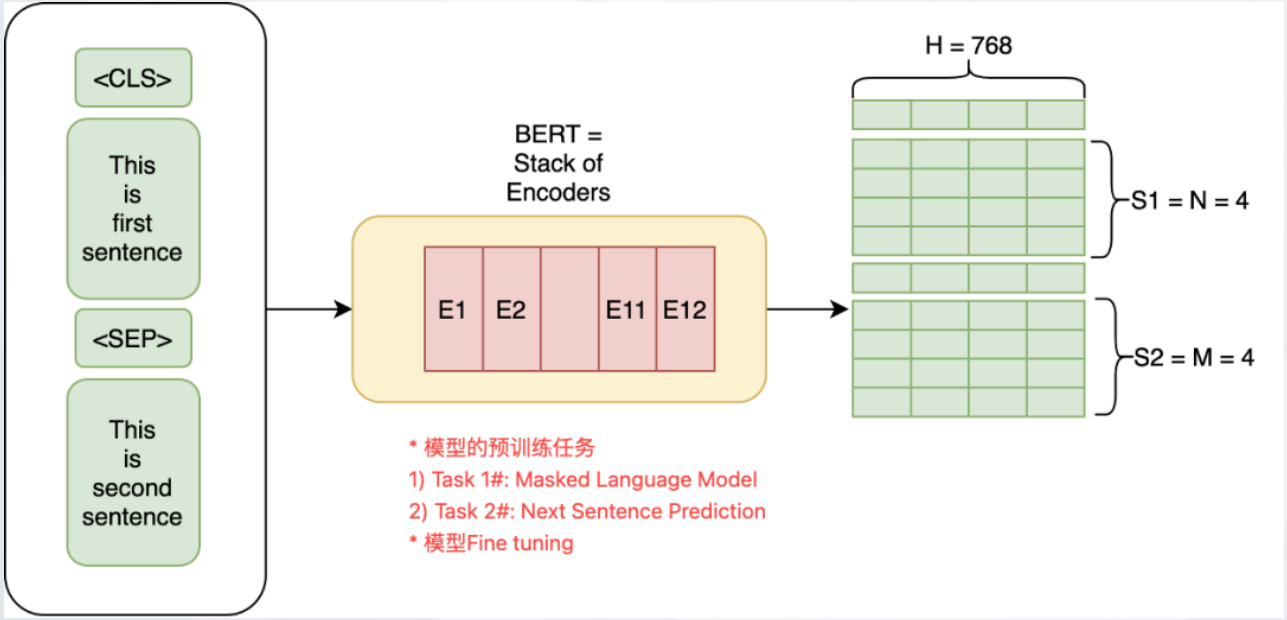
BERT（Bidirectional Encoder Representations from Transformers）是谷歌在2018年发布的自然语言处理模型，它彻底改变了NLP领域的发展轨迹。在BERT出现之前，主流模型如Word2Vec只能提供静态的词向量表示，这些方法虽然解决了词汇的分布式表示问题，但无法处理一词多义和复杂的上下文信息。例如，“苹果”这个词在不同语境中既可能指水果，也可能指美国苹果科技公司，传统模型无法区分这种差异。



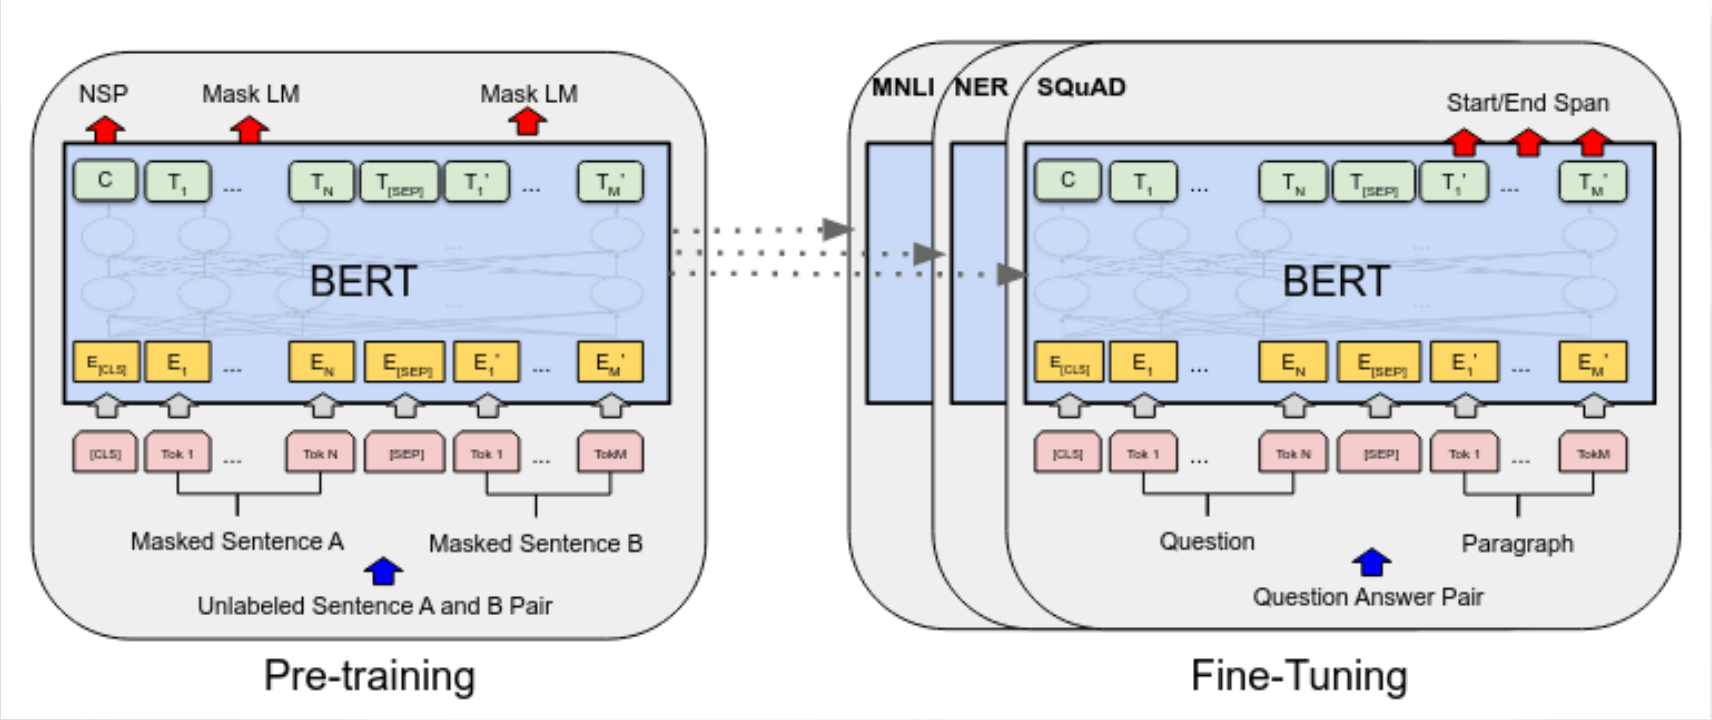
2.2 BERT



BERT的工作原理是通过在大规模未标注数据上执行预训练任务（如Masked Language Model来捕获文本中词汇的双向上下文关系，以及Next Sentence Prediction来理解句子间的逻辑关系），再将预训练的模型针对特定任务进行Fine tuning，从而在各种自然语言处理任务中实现高性能。

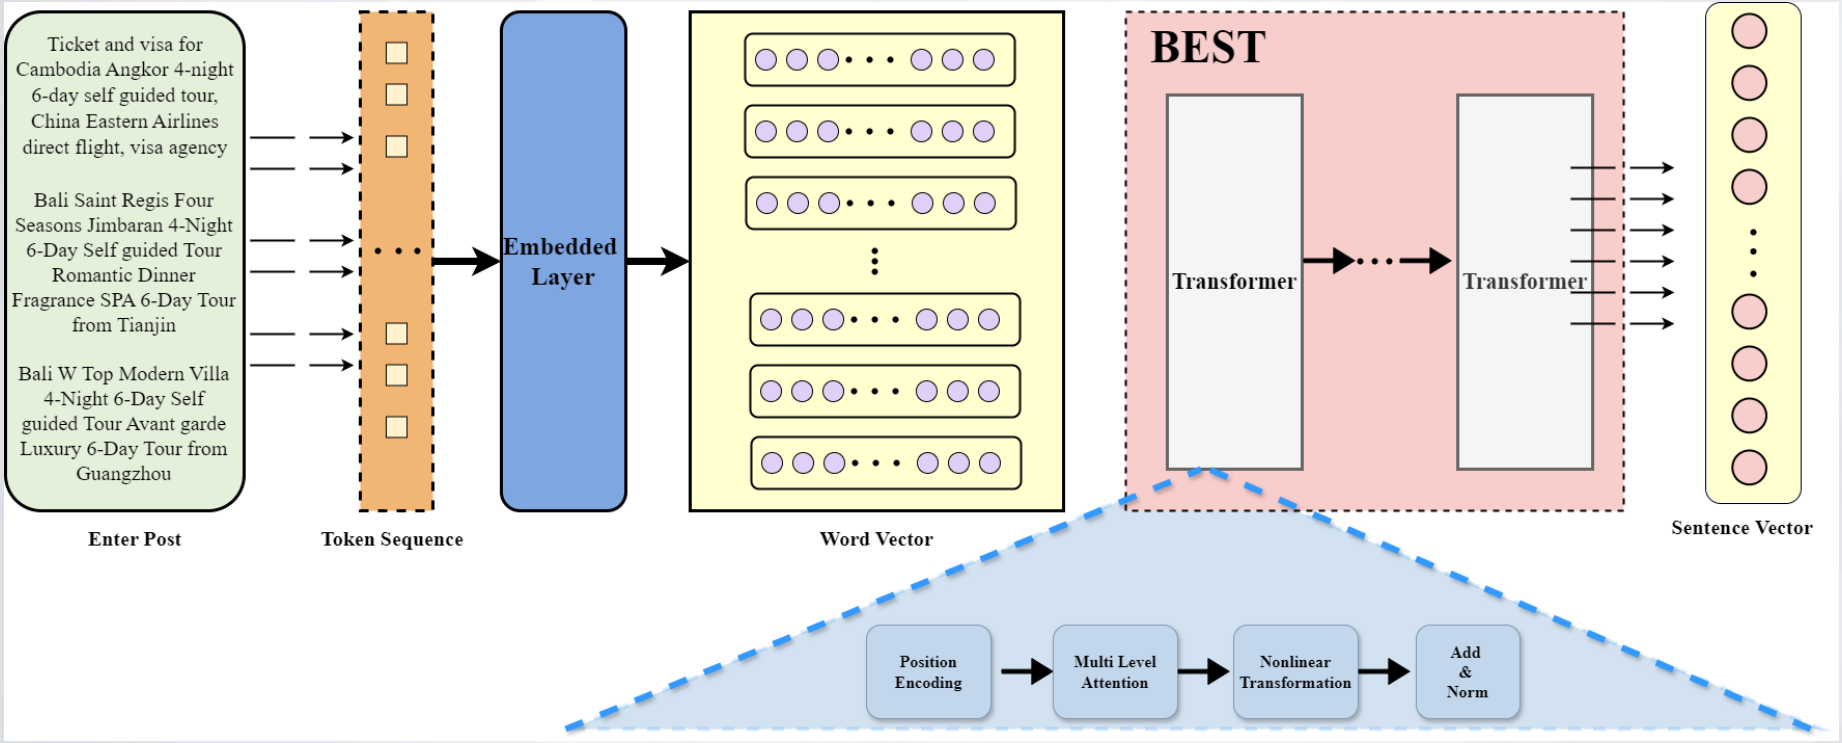


2.2 BERT



微调的目的是通过调整 BERT 模型的参数，使其更好地适应数据，从而优化 BERT 模型，使其在特定任务中表现出色。例如，可以在较小的电影评论数据集上对在大型文本数据语料库上预先训练好的 BERT 模型进行微调，以提高其准确预测特定评论情感的能力。

2.3 BERT应用案例


Ticket and visa for Cambodia Angkor 4-night 6-day self guided tour, China Eastern Airlines direct flight, visa agency
Bali Saint Regis Four Seasons Jimbaran 4-Night 6-Day Self guided Tour Romantic Dinner Fragrance SPA 6-Day Tour from Tianjin
Bali W Top Modern Villa 4-Night 6-Day Self guided Tour Avant garde Luxury 6-Day Tour from Guangzhou
Enter Post
Token Sequence
Embedded Layer
Word Vector
BEST
Transformer
Transformer
Sentence Vector
Position Encoding
Multi Level Attention
Nonlinear Transformation
Add & Norm

2.3 BERT应用案例



对于2个以海岛游的为主题的旅游产品，产品编号为‘502287105’的‘马尔代夫 维拉沙露岛 Velassaru 4晚 6日 自助游 香港 斯航 高级房 水上 别墅’和‘产品编号为‘502288601’的‘巴厘岛 宝格丽 BVLGARI 无敌 海景 下午茶 天坛 秀 一日游’，依据公式得出他们的语义相似度高达0.9211。相反，而对2个不同地区的产品，产品编号为‘13543’的‘北京 双飞 5日游 正宗 八达岭长城 标准’和编号为‘8250’的‘上海 豪华 游船 东方明珠 都市 观光 1日’，依据公式得出他们的语义相似度低至0.8219。

```
[40]: text1 = "北京 双飞 5日游 正宗 八达岭长城 标准"
      text2 = "上海 豪华 游船 东方明珠 都市 观光 1日"
      embedding1 = get_embedding(text1)
      embedding2 = get_embedding(text2)

      similarity = cosine_similarity([embedding1], [embedding2])[0][0]

      print(f"相似度: {similarity}")

      相似度: 0.8219725489616394

[56]: text1 = "巴厘岛 宝格丽 BVLGARI 无敌 海景 下午茶 天坛 秀 一日游"
      text2 = "马尔代夫 维拉沙露岛 Velassaru 4晚 6日 自助游 香港 斯航 高级房 水上 别墅"
      embedding1 = get_embedding(text1)
      embedding2 = get_embedding(text2)

      similarity = cosine_similarity([embedding1], [embedding2])[0][0]

      print(f"相似度: {similarity}")

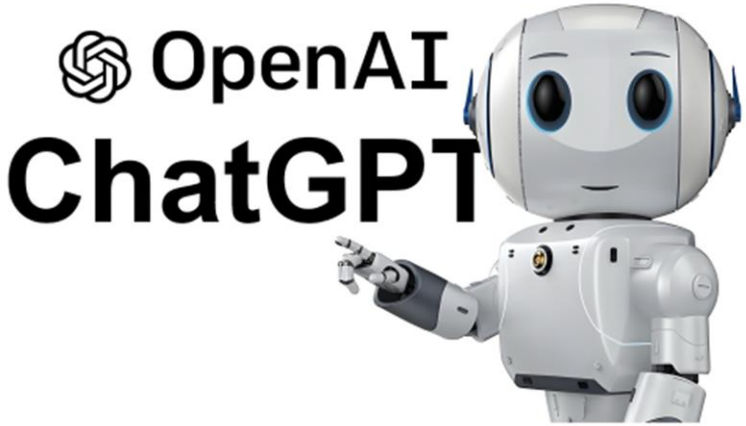
      相似度: 0.9210386276245117
```

03

以规模铸就优势——大模型技术

3.1 大模型前世今生

大模型 VS 小模型



如何看待世界互联网大会这个平台?

世界互联网大会是一个重要的国际平台，专门讨论互联网技术和其对社会、经济和文化的影响。这个平台汇聚了来自世界各地的互联网专家、技术人员、政府官员和商界领袖，共同探讨互联网发展的未来趋势和挑战。

世界互联网大会的重要性在于，它促进了全球互联网技术和应用的发展，促进了国际间的技术交流和合作。它还为政府、企业和其他组织提供了一个展示最新互联网技术和创新成果的平台，

你能帮我写个类似于"羊了个羊"的小程序代码嘛

当然可以！这是一份用 Python 实现的"羊了个羊"小程序代码：

python Copy code

```python
import random

def sheep_game():
    # 设置羊数量
    sheep_count = random.randint(10, 100)

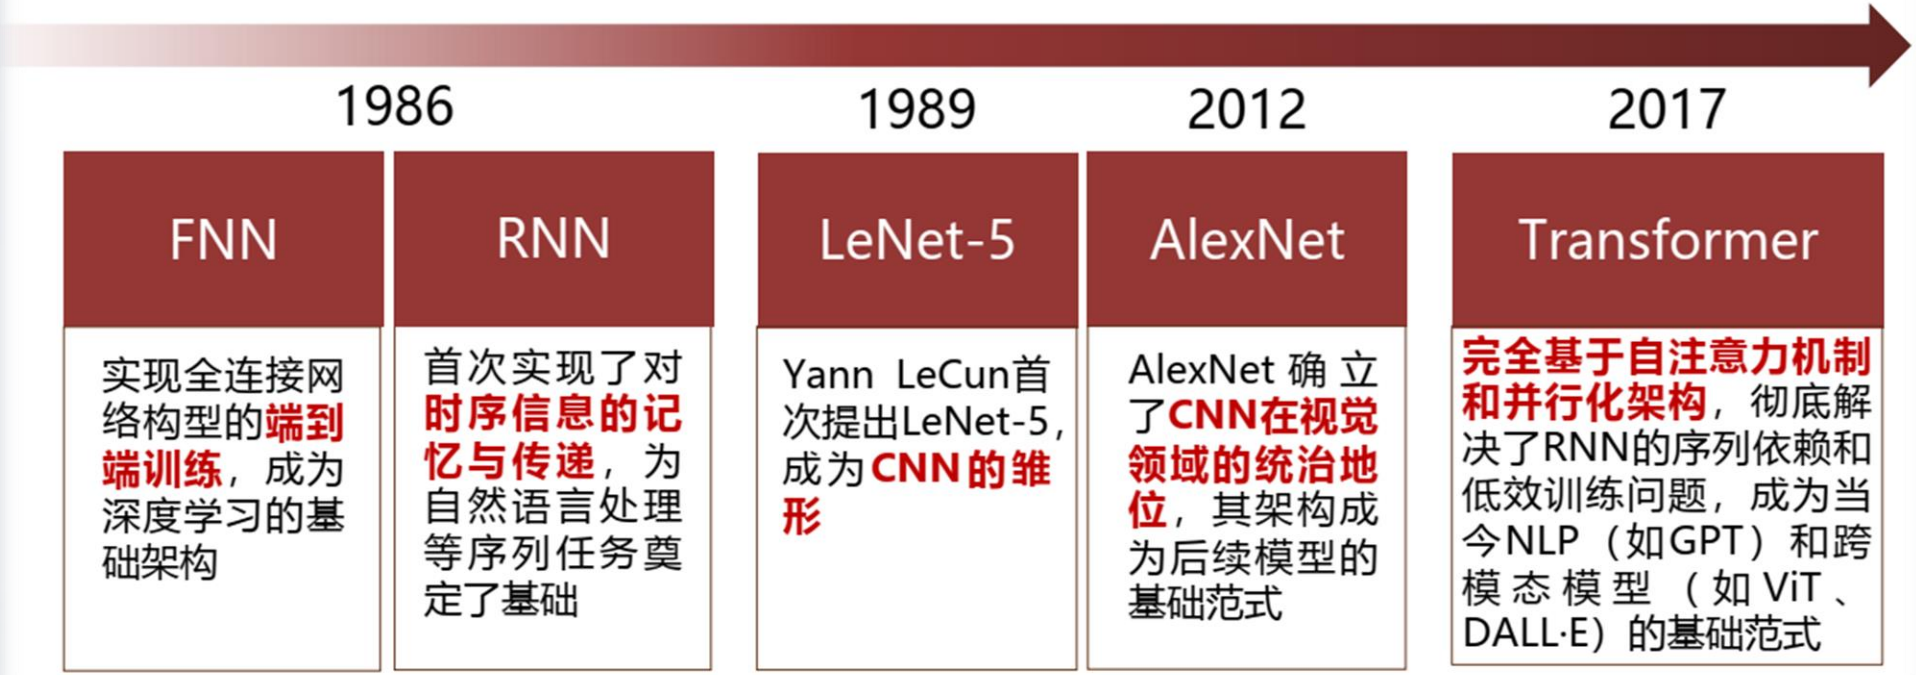
    # 设置循环次数
    loop_count = 0

    while sheep_count > 0:
        print("羊数量：", sheep_count)
        sheep_count -= 1
        loop_count += 1

    print("经过了", loop_count, "次，羊了个羊，所有羊都被羊完了。")
```

3.1 大模型前世今生

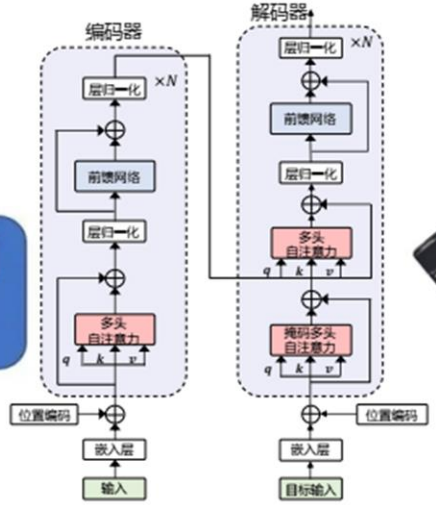
- 谷歌提出了Transformer架构，利用自注意力机制构建长程序列关系的同时，实现了对模型的并行化训练，这为研发大模型提供了可以并行优化的基础模型结构。

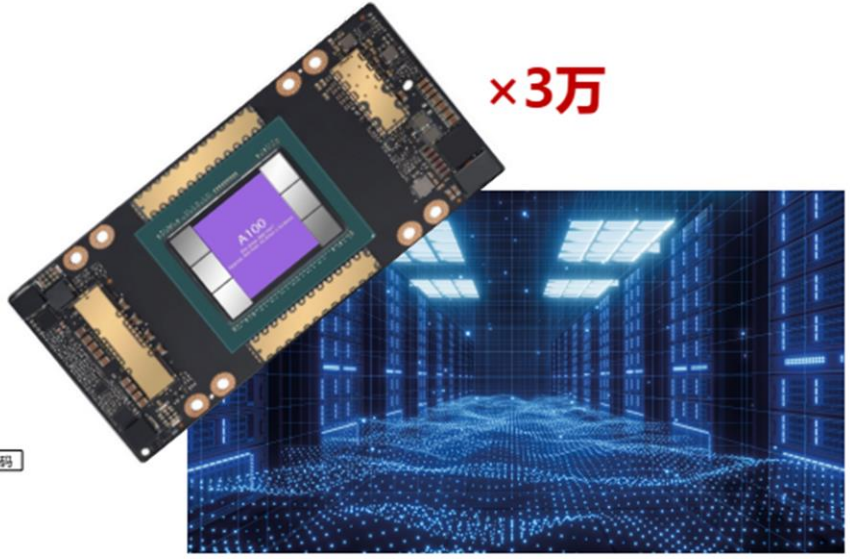


3.1 大模型前世今生

- 谷歌提出了Transformer架构，利用自注意力机制构建长程序列关系的同时，实现了对模型的并行化训练，这为研发大模型提供了可以并行优化的基础模型结构。





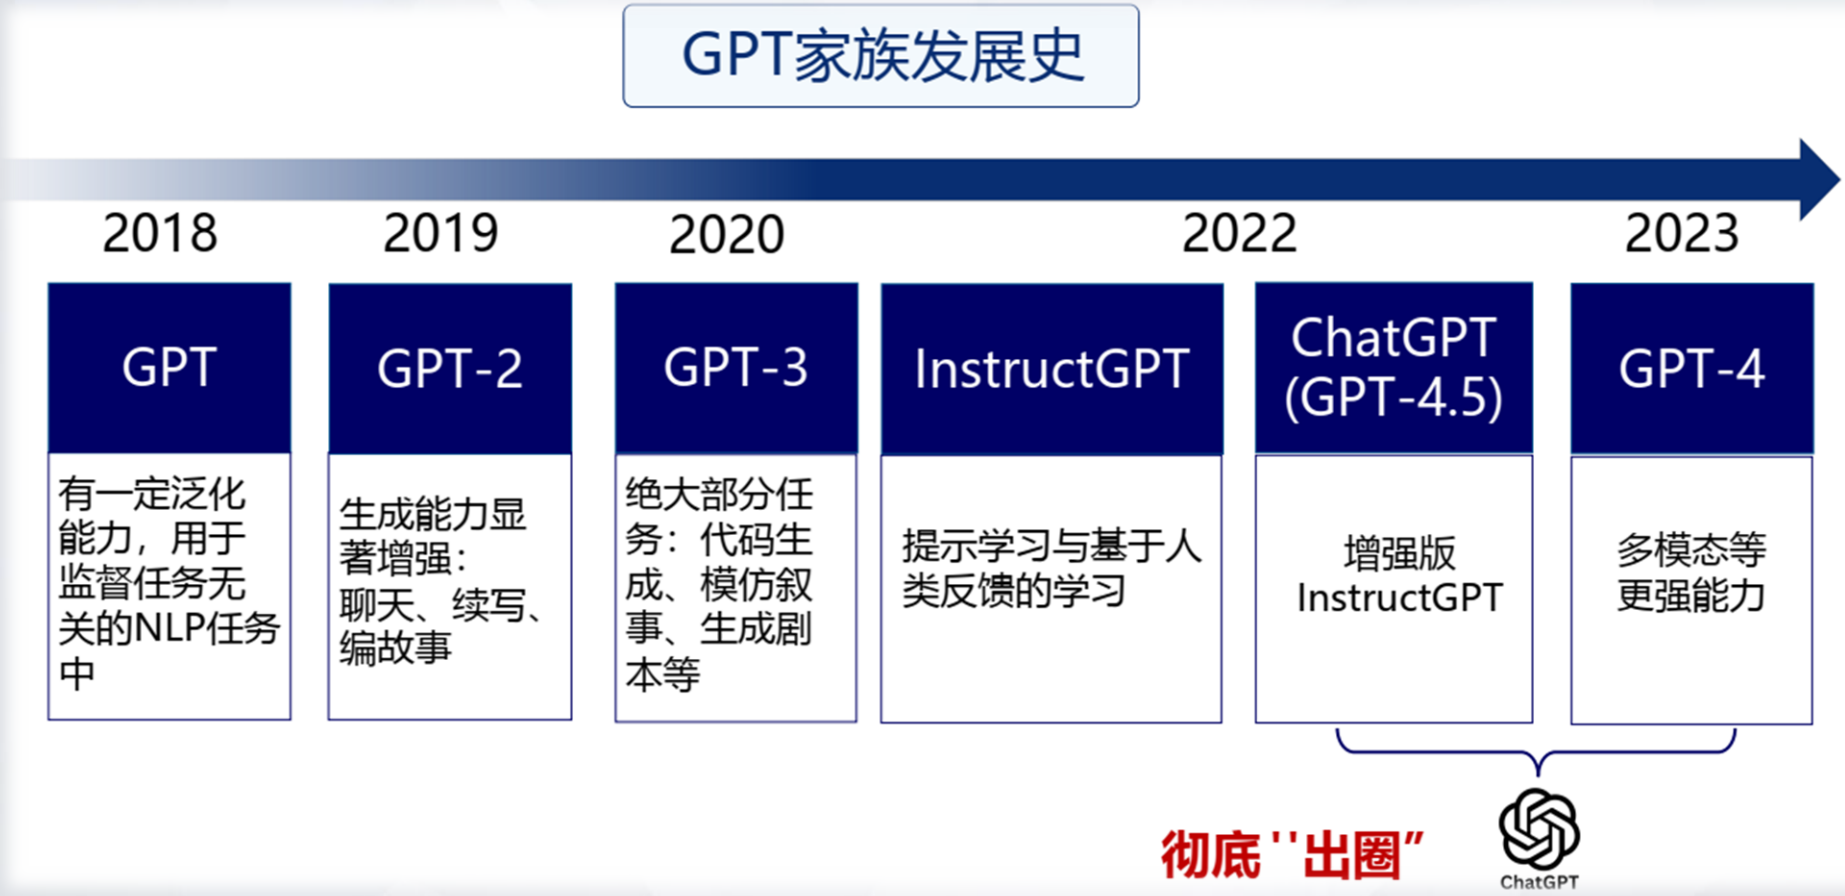


ChatGPT使用Transformer为核心组件

训练一个ChatGPT的模型
需要上万张A100！！！

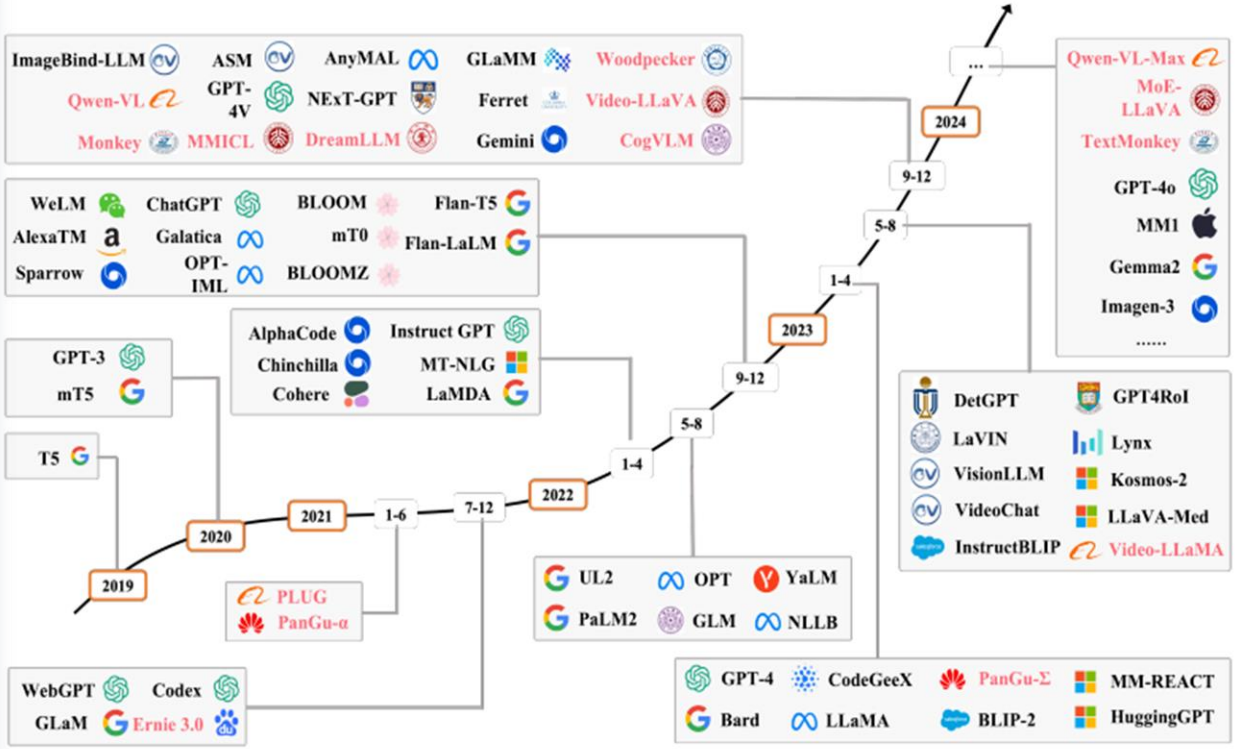


3.1 大模型前世今生


GPT家族发展史
2018
2019
2020
2022
2023
GPT
有一定泛化能力，用于监督任务无关的NLP任务中
GPT-2
生成能力显著增强：聊天、续写、编故事
GPT-3
绝大部分任务：代码生成、模仿叙事、生成剧本等
InstructGPT
提示学习与基于人类反馈的学习
ChatGPT (GPT-4.5)
增强版InstructGPT
GPT-4
多模态等更强能力
彻底"出圈"
ChatGPT

3.1 大模型前世今生

■ 大模型，顾名思义，是指那些参数规模巨大、计算量复杂的深度学习模型。



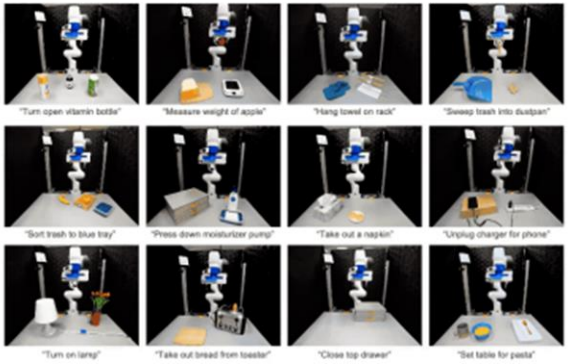
规模持续扩大提升性能

多模态融合增强应用能力

行业定制化满足垂直需求

3.1 大模型前世今生

■ 大模型的优势与挑战皆根植于其“大”这一本质特征之中。



- **零样本迁移能力：**模型在没有见过特定任务的训练数据的情况下，仅根据已有的知识和对其他相关任务的学习经验，就能对该新任务进行处理和做出合理预测的能力。而且大模型通常可以在多个任务之间迁移和共享知识，这意味着在特定任务上训练的大模型可以迅速适应其他相关任务。



- **涌现能力：**随着模型规模的增大，模型表现出一些原本在较小规模时没有明显出现的新功能或特性。这些能力往往不是通过明确的编程或者训练目标获得的，而是在模型的规模达到一定程度后自发涌现的，称为“涌现能力”。

3.1 大模型训练与优化

■ **大模型的研发主要分为两个阶段，即预训练阶段和微调与对齐阶段。**

➢ **预训练**是大模型研发的关键阶段，其成效直接关乎模型后续能力的广度与深度。预训练阶段首先要准备的便是大规模、高质量的训练数据。

例句：张明正在$#&学习大模型的相关内容。张明正在学习大模型的相###关内容。



3.1 大模型训练与优化

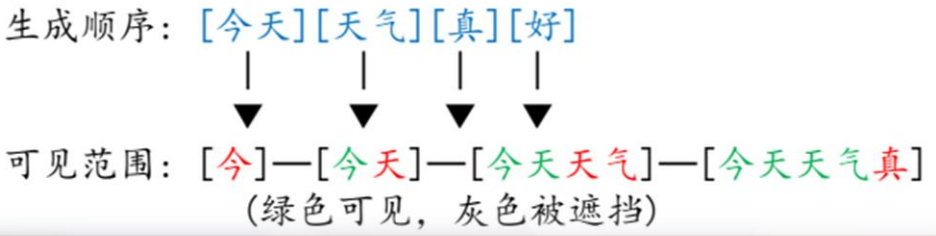
■ **大模型的研发主要分为两个阶段，即预训练阶段和微调与对齐阶段。**

➢在模型架构方面，目前国内外主流的大模型主要基于Transformer框架包括以下3种：

- 编码器-解码器（Encoder-Decoder）—— "翻译官模式"



- 因果解码器（Causal Decoder）—— "写日记模式"

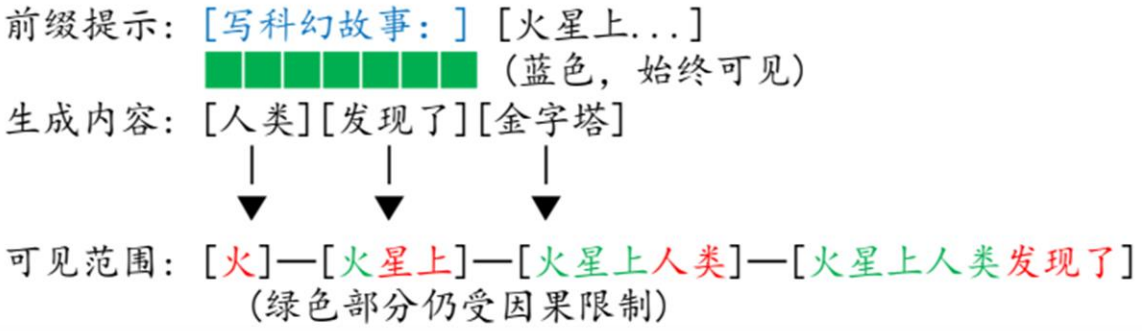


3.1 大模型训练与优化

■ **大模型的研发主要分为两个阶段，即预训练阶段和微调与对齐阶段。**

➢在模型架构方面，目前国内外主流的大模型主要基于Transformer框架包括以下3种：

- 编码器-解码器（Encoder-Decoder）—— "翻译官模式"
- 因果解码器（Causal Decoder）—— "写日记模式"
- 前缀解码器（Prefix Decoder）—— "命题作文模式"



3.1 大模型训练与优化

- 在进行大规模预训练时，往往需要设计合适的**自监督预训练**任务，使得模型能够从海量无标注数据中学习到广泛的语义知识与世界知识。

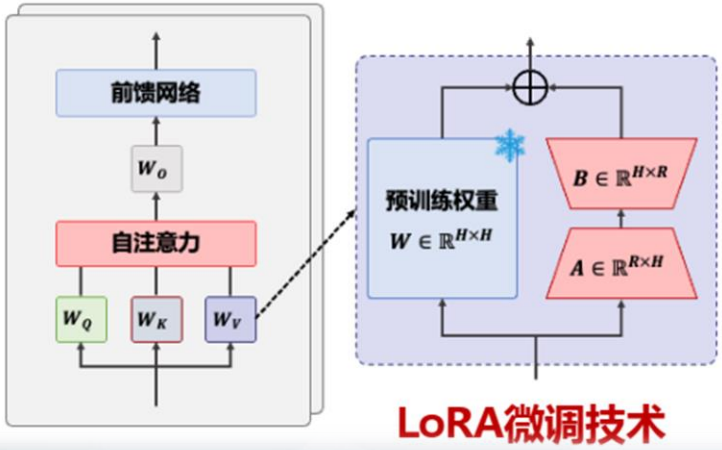
	语言建模	去噪自编码器	混合去噪器
目标	学习词元序列的概率分布	学习从破坏的文本中恢复原始文本	学习从多种破坏模式中恢复原始文本
输入	完整的文本序列	被破坏的文本	被多种方式破坏的文本
输出	无	删除、替换、重排词元等	多种噪声类型（如删除、替换、重排等）
噪声强度	无	固定或可调	可调
模型结构	编码器	编码器+解码器	编码器+解码器
训练目标	最大化下一个词元的预测概率	最小化重构文本与原始文本的差异	最小化重构文本与原始文本的差异
损失函数	负对数似然	均方误差或交叉熵损失	均方误差或交叉熵损失
应用场景	序列生成、翻译、问答等	文本补全、错误纠正、文本恢复等	多种文本处理任务，增强鲁棒性和泛化能力
鲁棒性	较低	较高	更高
泛化性	中等	较强	更强
优点	学习词元间依赖关系	提高模型对抗噪声的能力	提高模型对抗多种噪声的能力
缺点	可能忽视上下文信息	只能处理特定类型的噪声	训练过程可能很复杂

3.1 大模型训练与优化

- 在特定的应用场景下，需要对大模型进一步优化，使其能够有效地应用预训练阶段获取的知识，并理解、适应人类意愿，在不同任务下表现出优秀的准确性和适用性，从而更好地服务于实际应用需求。

指令微调：收集或构建指令化的实例，然后通过有监督的方式对大语言模型的参数进行微调。

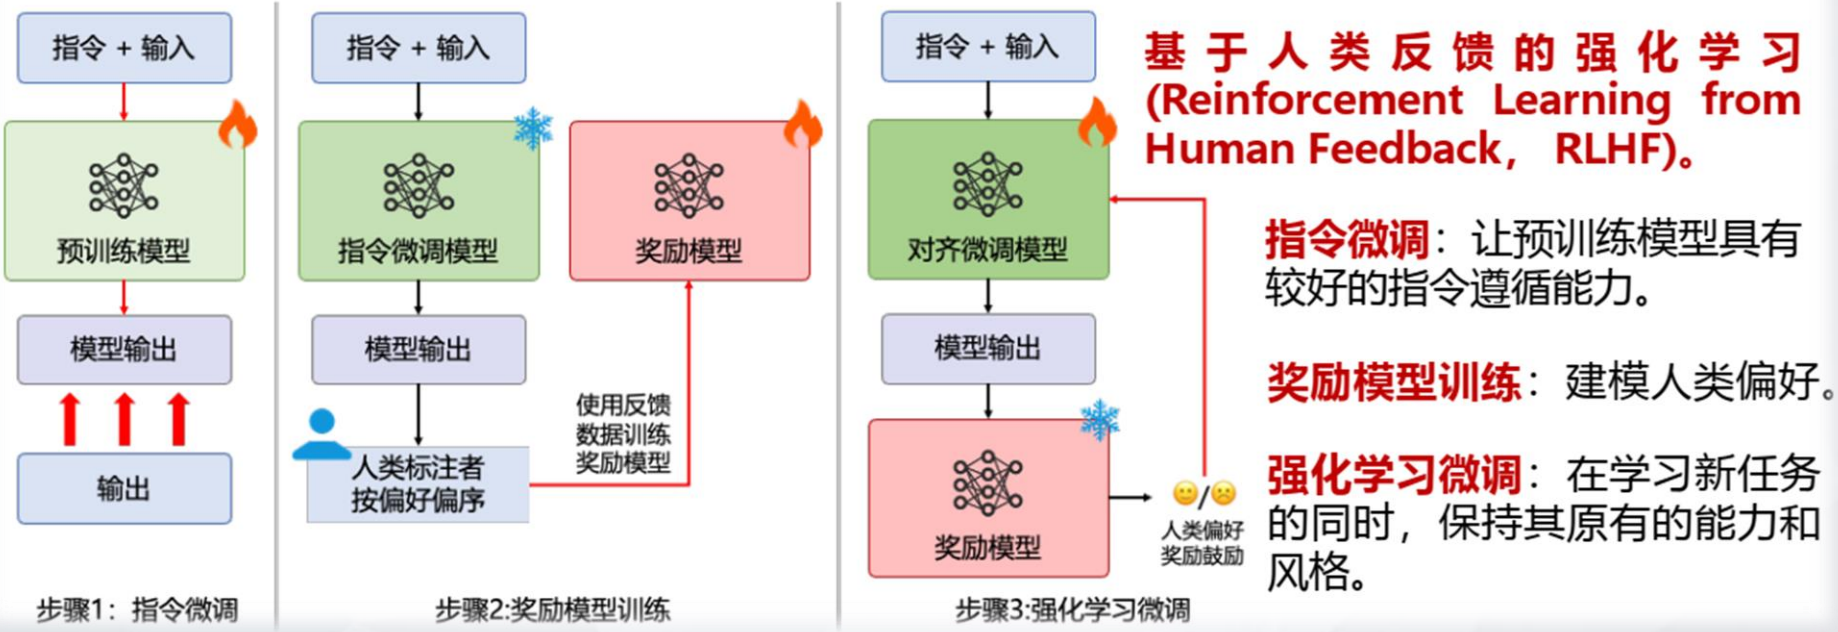




LoRA微调技术：在不修改原有模型权重的情况下，通过引入低秩矩阵来调整模型的某些层，从而实现快速适应新任务的目的。

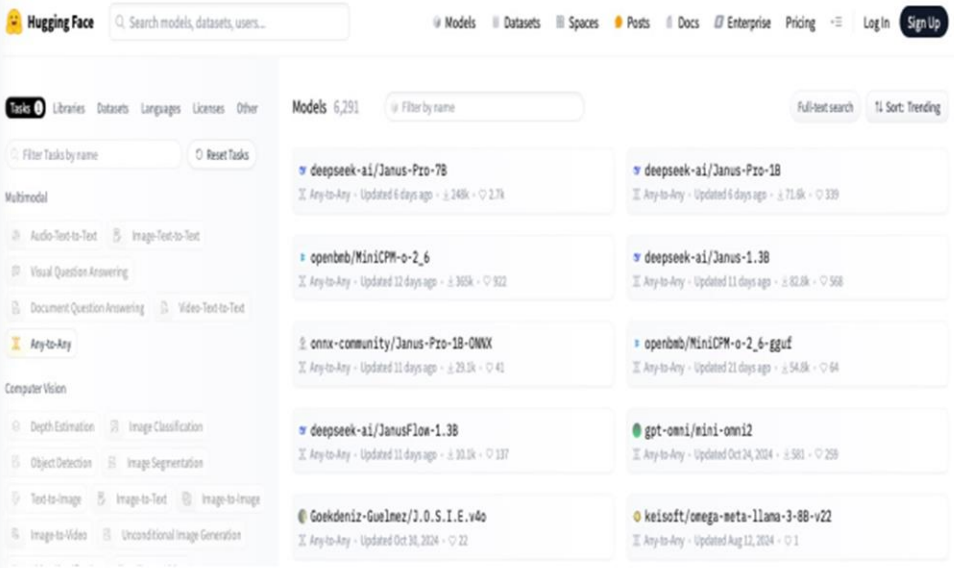
3.1 大模型训练与优化

- 在特定的应用场景下，需要对大模型进一步优化，使其能够有效地应用预训练阶段获取的知识，并理解、适应人类意愿，在不同任务下表现出优秀的准确性和适用性，从而更好地服务于实际应用需求。



3.1 大模型训练与优化

- 目前大模型的性能依然在持续不断地刷新，并不断有新的大模型推出，如火爆出圈的“国货之光”Deepseek大模型，堪称大模型的性价比典范。





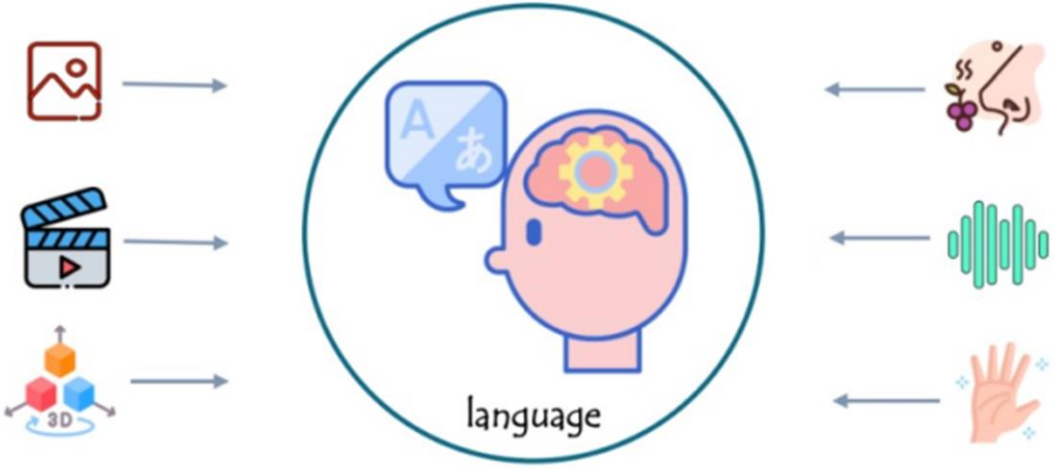
Hugging Face https://huggingface.co/

04

全能王者——多模态大模型

4.1 多模态大模型的概念与演进

- 大语言模型，与其他模态的模型连接起来，实现协同对推理，催生了一个新的研究领域——**多模态大语言模型（Multi-Modal Large Language Model, MLLM）**

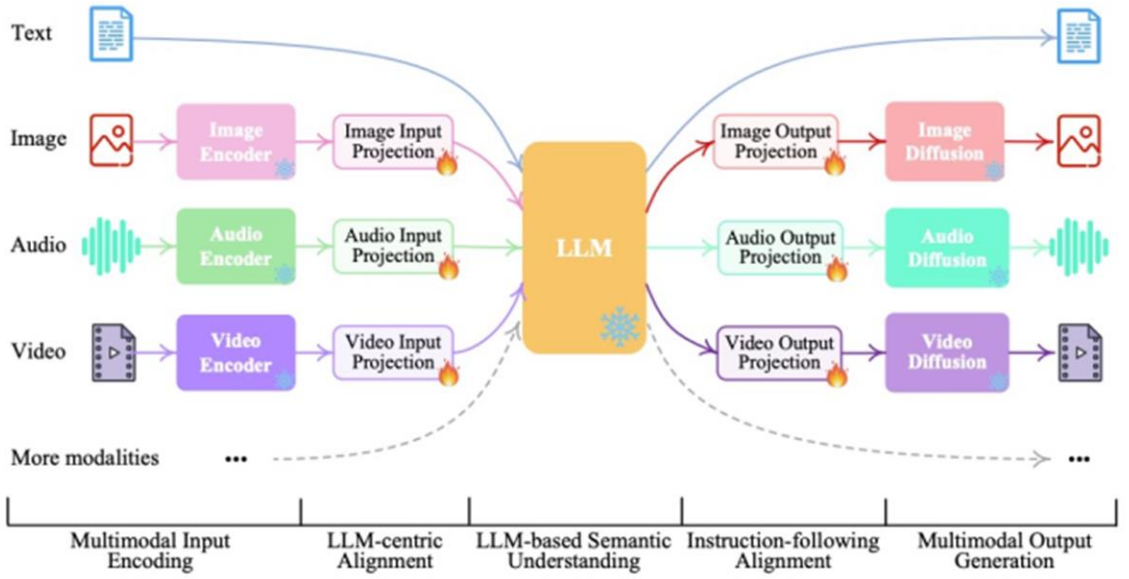


- 图像、视频、音频等多个模态信息之间的相互作用
- 跨模态理解的任务表现
- 视觉或听觉信息理解

多模态大语言模型通过对多种模态数据的联合学习和推理，模型能够捕捉到不同模态之间的内在关联和互补信息，从而更全面地理解和描述现实世界中的事物和现象。

4.1 多模态大模型的概念与演进

- 多模态大模型的关键能力在于整合并理解不同的数据格式，应用于需要理解和整合不同类型数据信息的任务。**LLMs处于核心位置，多模态在LLMs基础上进行扩展**，即找到一个方法将不同模态的数据映射到LLMs可以接收的语义空间。



多模态编码器： 负责将不同模态的输入数据编码为模型可理解的表示。

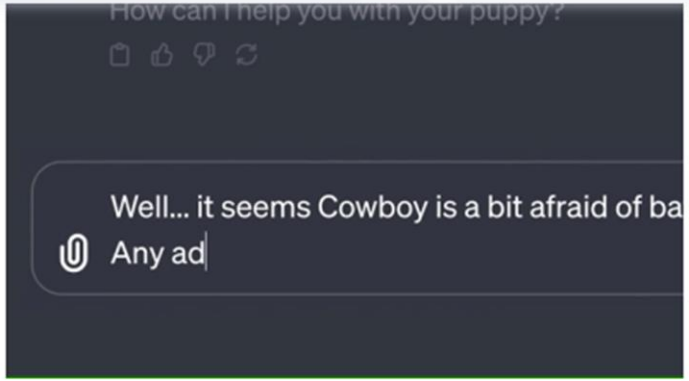
输入映射： 将不同模态的输入数据映射到共享的语义空间。

LLMs： 大型语言模型，用于处理文本数据。

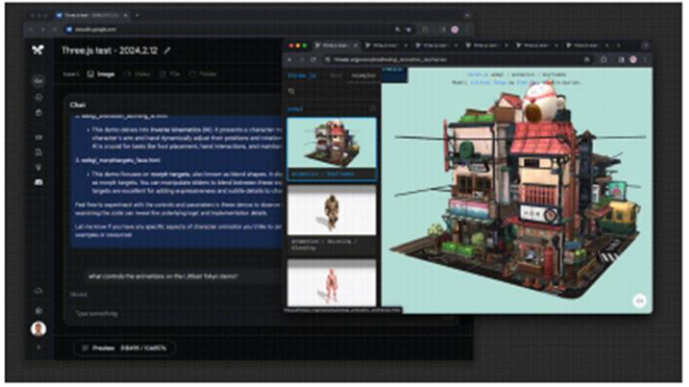
输出映射： 将模型生成的输出映射回原始模态的空间。

多模态生成器： 根据输入数据生成对应的输出数据。

4.1 多模态大模型的概念与演进



GPT-4理解图片信息充当宠物助手



Gemini进行3D场景重建

多模态内容理解和文本生成

Flaminigo　BLIP-2　MiniGPT-4

特定模态内容生成

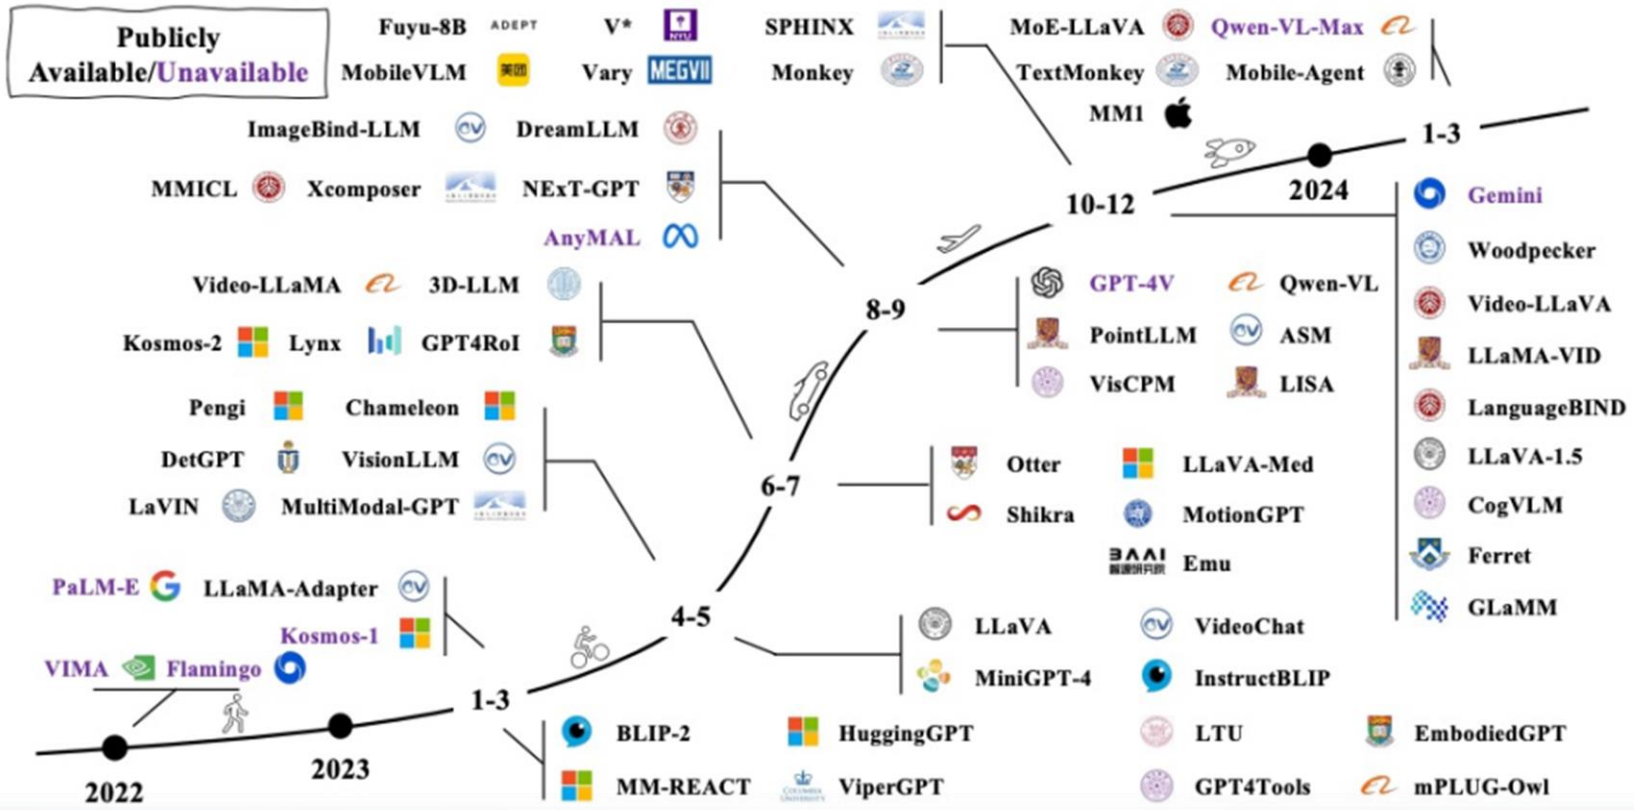
Kosmos-2　MiniGPT-5　SpeechGPT

各种模态内容生成

ViperGPT　AudioGPT　NExTGPT

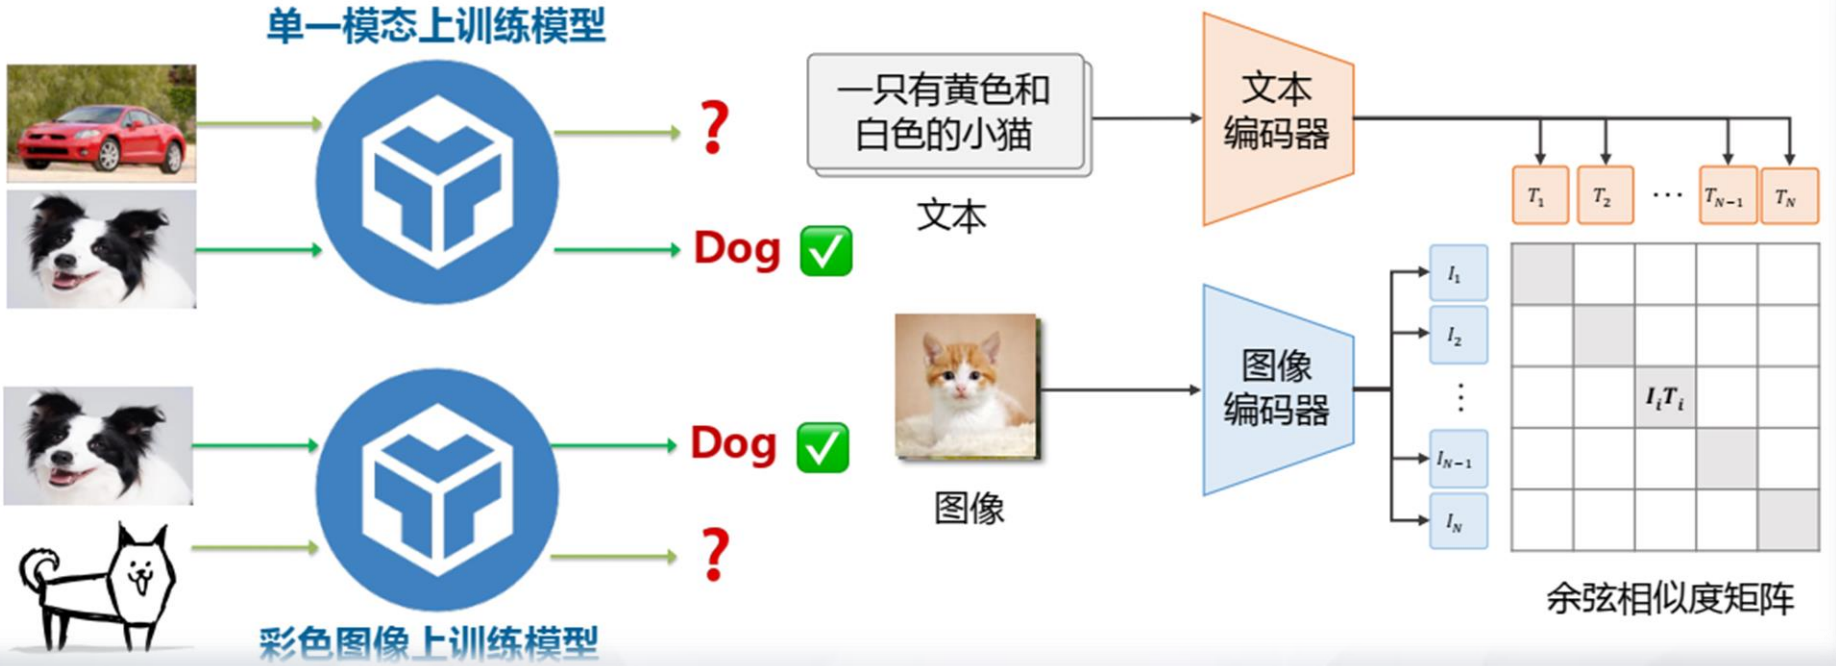
4.1 多模态大模型的概念与演进

■ 多模态大模型历经融合发展，如今其综合处理能力不断提升，在各行业广泛应用。

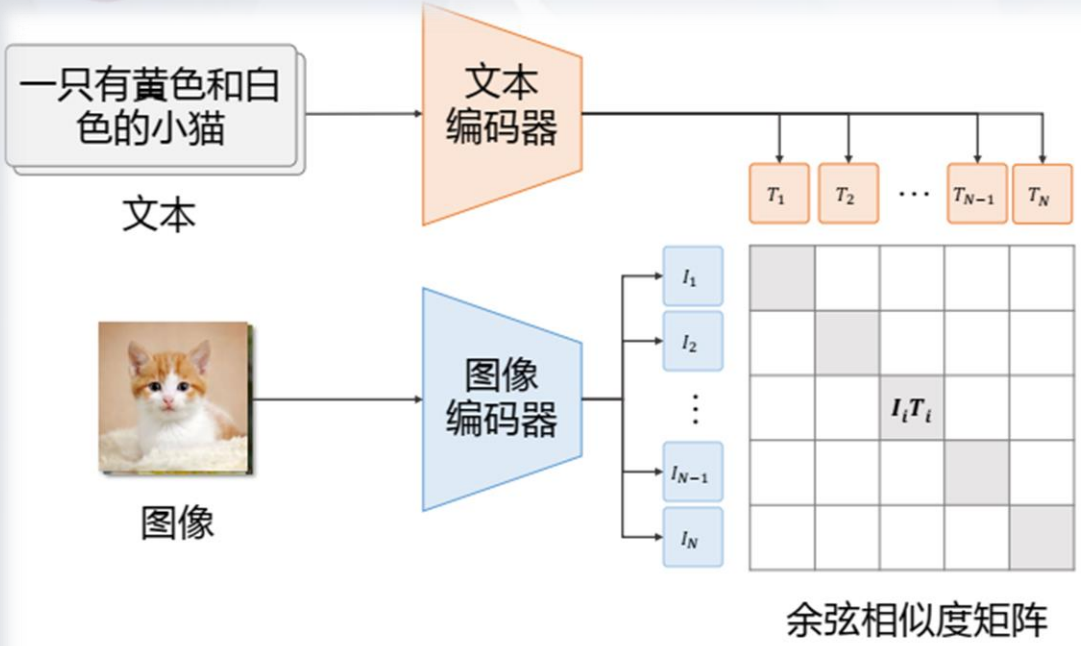


4.2 CLIP-多模态大模型的先驱

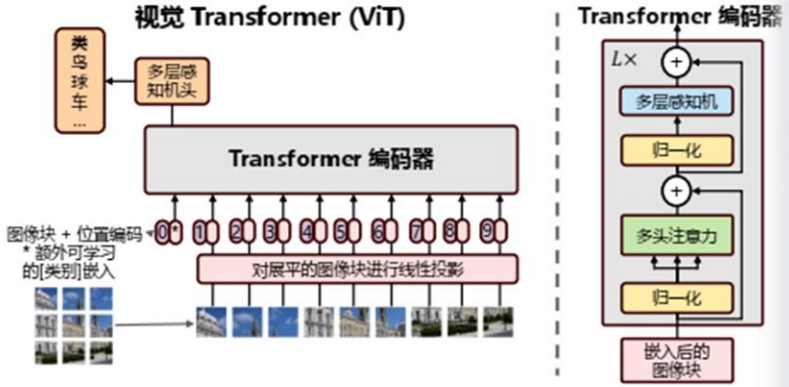
- CLIP（Contrastive Language-Image Pre-training）探索了如何利用大规模未标注数据进行有效的多模态学习，在图像分类、检索和生成等任务上表现出了强大的迁移能力，为多模态大模型的发展提供了重要的技术借鉴和思路启发。



4.2 CLIP-多模态大模型的先驱

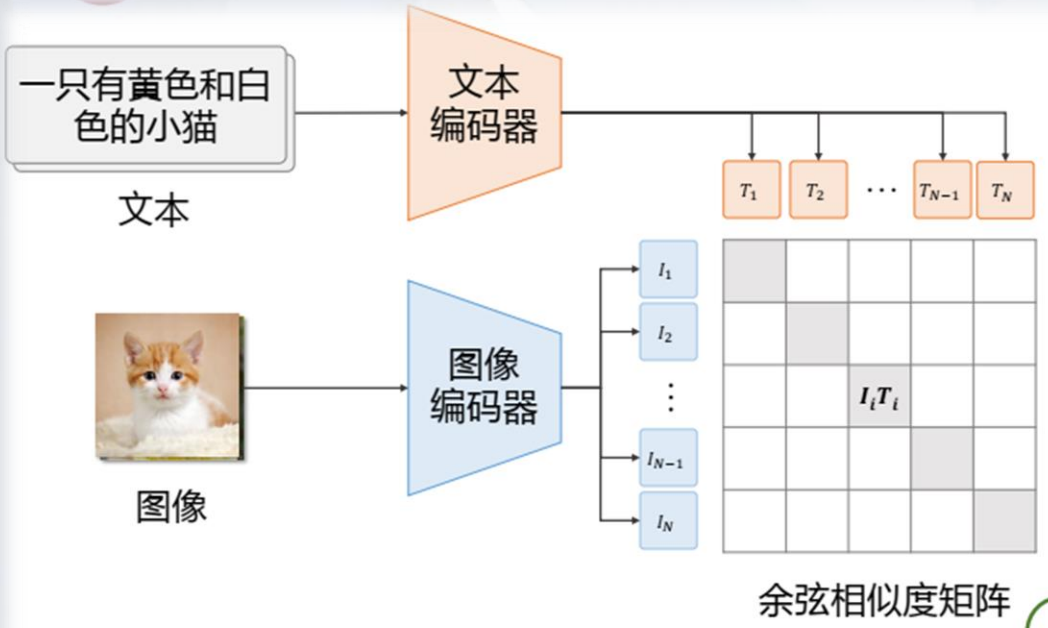


- CLIP模型采用了一种双塔架构，分别是图像编码器和文本编码器，用于处理图像和文本数据。



在文本编码器方面，CLIP沿用了GPT-2的架构；而在图像编码器的设计上，CLIP经过多次尝试，比较了不同的ResNet和Transformer架构，最终选择了ViT模型作为其图像编码器。

4.2 CLIP-多模态大模型的先驱



- CLIP模型采用了一种双塔架构，分别是图像编码器和文本编码器，用于处理图像和文本数据。
- 采用了自监督学习的方法，通过对大量无标签的图像-文本对进行训练来学习图像和文本之间的对齐关系。
- 通过对比学习的方法，将图像和文本映射到同一个高维语义空间中，使得它们能够在这个空间中相互理解和交互。

$$S = \left(I_E \cdot T_E^{\mathrm{T}}\right) \times e^{\varepsilon} \in \mathbb{R}^{N \times N}$$

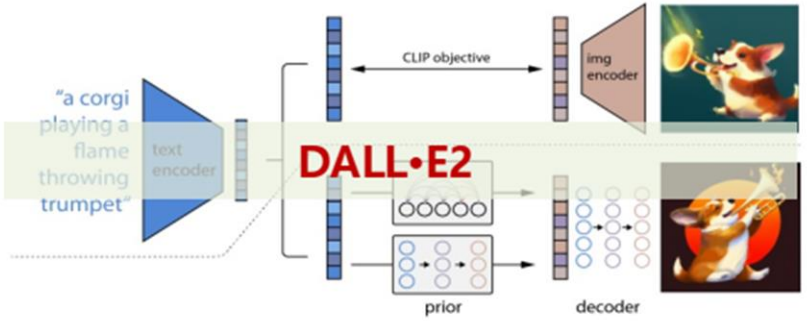
对比学习 最大化对角线上的相似度值（正确匹配）
尽可能减小非对角线上的值（错误匹配）

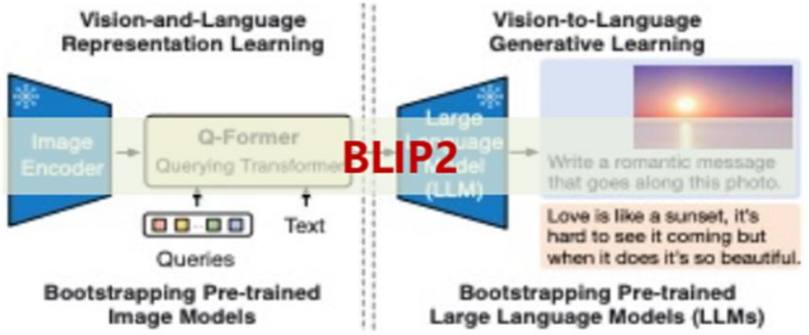
科普一下 **对比学习**

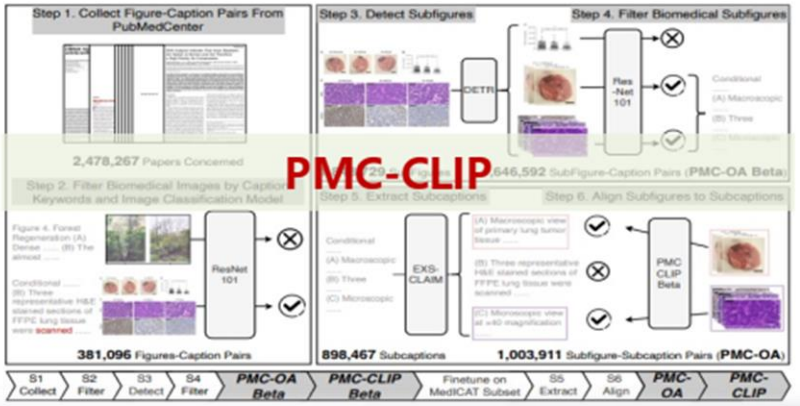
对比学习是一种自监督学习方法，通过将相似样本的特征拉近、不相似样本的特征推远，来学习数据的有效表示。具体来说，模型会构建正样本对（相似样本）和负样本对（不相似样本），通过优化损失函数，使正样本对在特征空间中更接近，负样本对更远离。

4.2 CLIP-多模态大模型的先驱

- CLIP通过对比学习的方式学习到了图像与文本之间的潜在关联，实现了扩模态数据的有效融合，并开创自监督预训练典范，提升迁移学习能力。







4.3 基础大模型核心要点

■ 基础大模型是基石，是底座，是基座。





■ 垂域大模型是在特定领域精耕细作的“尖兵”。

4.3 基础大模型核心要点

■ 基础大模型是基于**大规模通用数据**预训练的模型，具备通用语言理解与生成能力。

- 从规模上看，它拥有海量参数，常达数十亿甚至数万亿，像 GPT-3 就有 1750 亿参数，如此规模能捕捉数据中复杂模式。
- 在通用性上，它不是针对特定任务，而是可处理多种类型任务和数据，比如文本、图像、语音等，像 BERT 模型能用于文本分类、问答等多种自然语言处理任务。
- 从功能上，它为下游任务和领域模型提供基础，通过微调适配具体应用场景，减少重新训练成本。



4.3 基础大模型核心要点

- 基础大模型虽然通用性强，但是专业性不足，并且存在数据安全与隐私问题，以及脏/假数据对于模型的损害风险，同时面临计算资源与推理效率挑战。

通用性与专业性

基础大模型通用性强，但在专业领域表现不够精准，难以满足精细化需求。在处理专业术语和复杂任务时存在局限，难以满足特定领域的专业需求。



数据安全与隐私

基础大模型使用大量通用数据，涉及数据安全和隐私问题。需加强数据加密和隐私保护，确保数据安全，数据安全是基础大模型的重要问题。





计算资源与效率

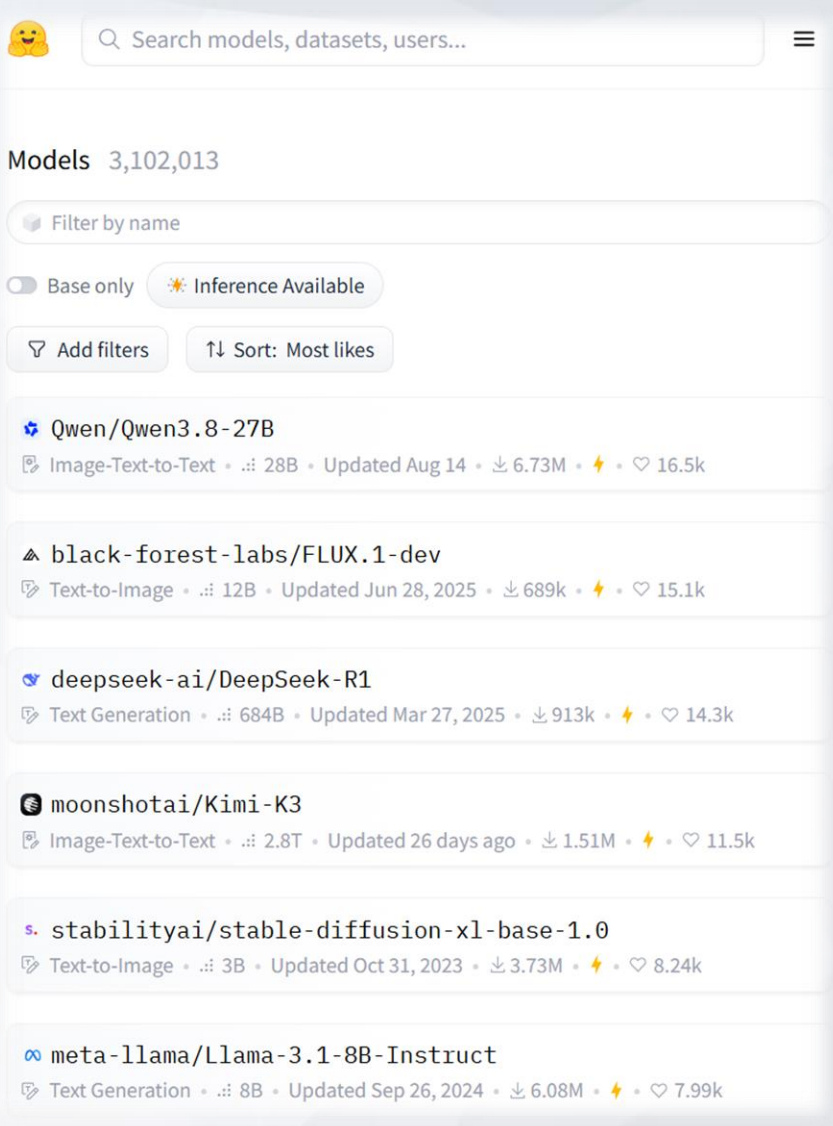
基础大模型训练和推理需要大量计算资源，计算成本较高。计算资源是基础大模型的瓶颈，优化资源使用可以提升模型训练和推理效率。



4.3 基础大模型核心要点

2026年8月17日，Hugging Face全球趋势榜的画风有些不一样。霸榜的不再是熟悉的硅谷明星，而是一个来自中国的模型——Qwen3.8-27B。





4.3 基础大模型核心要点





4.3 基础大模型核心要点

Qwen3-TTS

4.3 基础大模型核心要点



千问大模型 bilibili

4.4 垂类大模型—你想要的专才！

- 垂域大模型，也被称为领域大模型或行业大模型，是相对于通用基础大模型而言，针对特定垂直领域或行业进行专门设计、训练和优化的大型人工智能模型。
- 设计原则可遵循三阶段优化路径：领域数据收集与标注、知识融合以及模型优化。

领域针对性强　数据专业性强　任务特定性强　知识深度强

01

领域数据收集与标注：从专业数据库、行业报告、企业内部数据等多渠道收集数据，制定严格的标注规范，确保数据标注准确性和一致性。

02

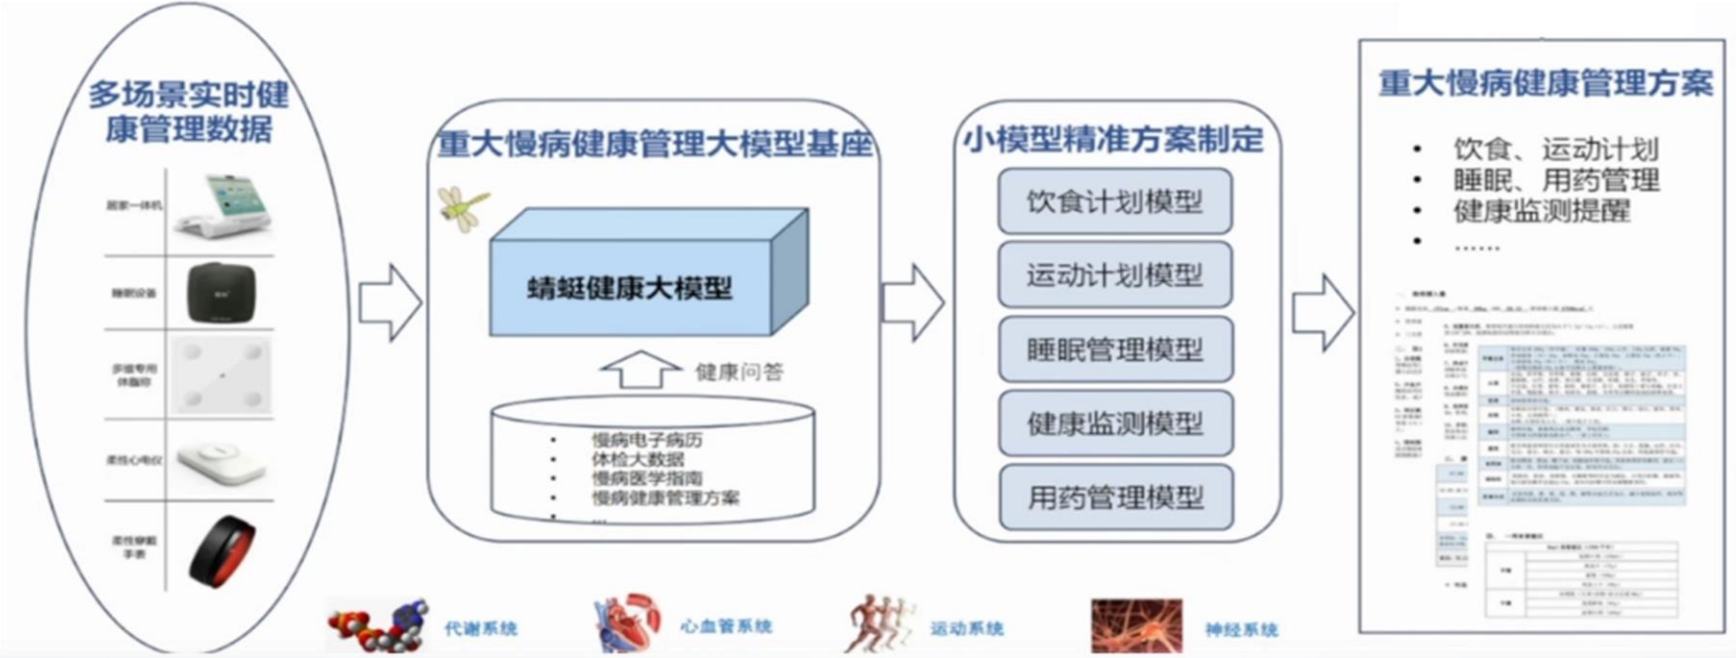
知识融合：构建领域知识图谱，将领域知识融入模型训练中，通过知识蒸馏、多模态融合等技术，提升模型对领域知识的理解和应用能力。

03

模型优化：根据领域数据特点和任务需求，对模型架构进行调整和优化，如增加特定领域的模块、调整网络层数和参数，以提高模型性能。

4.4 垂类大模型—你想要的专才！

- 垂域大模型，也被称为领域大模型或行业大模型，是相对于通用基础大模型而言，针对特定垂直领域或行业进行专门设计、训练和优化的大型人工智能模型。
- 设计原则可遵循三阶段优化路径：领域数据收集与标注、知识融合以及模型优化。

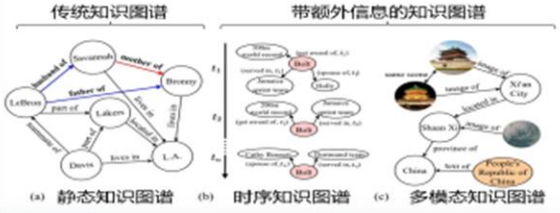


4.4 垂类大模型—你想要的专才！

■ **领域知识深度融合技术**进一步推动垂域大模型发展。

知识图谱增强推理

方法：实体链接+图神经网络，通过实体链接将文本实体与知识图谱对应，再用图神经网络推理实体间关系。



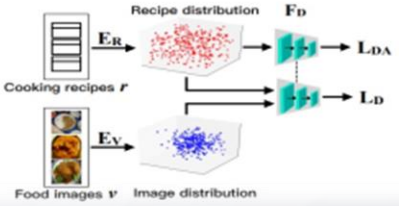
领域规则引导解码

方法：受限解码+规则模板，依据领域规则限制解码过程，确保生成内容符合规则。



多模态数据对齐

方法：跨模态对比学习，通过对比学习使不同模态数据特征对齐，提升模型对多模态数据理解。



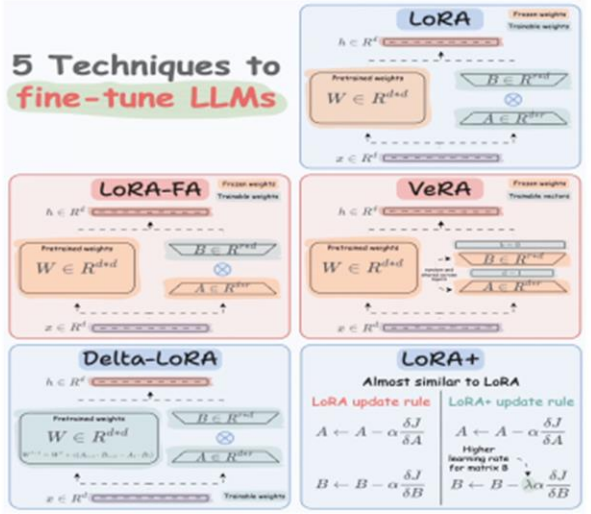
4.4 垂类大模型—你想要的专才！

■ **参数高效微调技术**是垂域大模型实现高效定制化的技术手段。

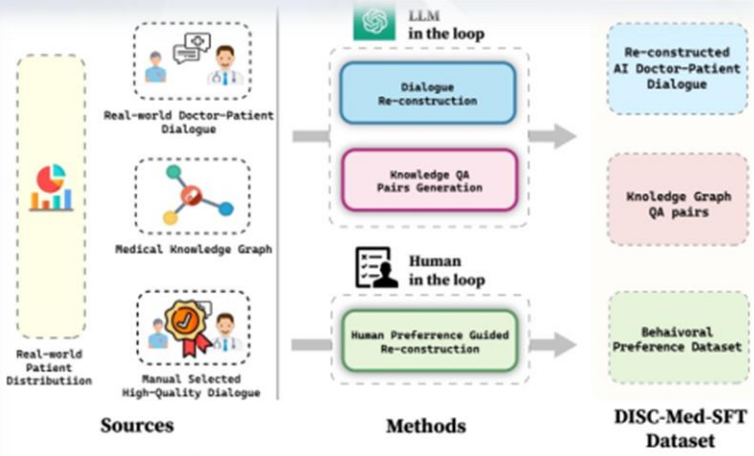
全量 Supervised Fine-tuning：使用大量标注数据进行微调，使模型在特定领域任务上达到更好的性能。参数量100%，训练成本高，适用于数据充足、算力充裕场景，能充分优化模型性能。

LoRA：通过低秩矩阵分解进行微调。在保持原模型性能的同时，适应特定领域的任务需求。参数量0.1-1%，训练成本极低，适用于低资源垂域适配，能在少量数据下快速优化模型。

Prefix-tuning：通过调整模型的提示词，引导模型输出。参数量0.1%，训练成本中等，适用于生成式任务控制，可有效控制生成内容方向。



4.4 垂类大模型—你想要的专才！



医疗大模型DISC-MedLLM



安恒信息恒脑大模型

基于**Baichuan13BBase基础大模型指令微调**得到

DISC-Med-SFT训练集，包含超过**47万个来源于现有的多个医疗数据集的不同示例**。

以**大模型为底座，以智能体为核心**，实现安全能力场景化调度，

2024年唯一入选工信部“未来产业领域”案例名单的安全垂域大模型

05

让AI从“能说会道”到“动手干活”——龙虾OpenClaw

5.1 OpenClaw本质与定位

OpenClaw（“龙虾”，曾用名：Clawdbot、Moltbot）是奥地利程序员彼得·斯坦伯格开发的开源AI智能体，于2025年11月推出。该智能体具备本地数据主动采集能力，可在未经用户明确授权的情况下自动读取终端敏感信息，并结合系统级权限实现远程控制、数据外传等恶意行为。核心架构由Gateway（网关）、Agent（智能体）、Skills（技能）和Memory（记忆）构成。

用户可通过WhatsApp、Slack等即时通讯工具作为交互界面与系统对接。部署在本地电脑并获得相应权限后，可以直接访问系统。通过部署多台电脑和多个智能体，可以实现自动化处理邮件、阅读文档、编写代码、发布社交媒体内容等工作。



5.1 OpenClaw本质与定位

OpenClaw并非全新的大语言模型，而是一个开源的AI智能体框架与执行网关。它作为24小时在线的"数字员工"，通过连接聊天入口与大模型，调用各类工具自主执行复杂任务，实现了AI从"提供建议"到"直接干活"的跨越。

- 核心定位为本地优先的AI自动化代理引擎，遵循MIT开源协议，支持macOS、Windows、Linux及移动端等全平台部署运行 — 全平台
- 扮演"数字员工"角色，连接WhatsApp、微信等聊天入口与大语言模型，将用户的自然语言指令转化为具体的计算机操作 — 数字员工
- 具备24小时全天候在线能力，部署后可在后台持续运行，即使用户离线也能自动处理邮件、整理文件或执行定时任务 — 24h在线
- 采用模型无关设计，兼容Kimi、Claude、OpenAI等200多款主流大模型，用户可根据任务需求灵活切换底层"大脑" — 200+模型



5.2 OpenClaw现象级爆红：符号化传播与生产力革命

OpenClaw在中国的爆红是技术必然与市场偶然的叠加。龙虾Logo被转化为"养龙虾"的生活化隐喻，降低传播门槛，同时切中职场人对AI自动化提效的深层渴望。代表了AI从"只会说"到"会做"的实质性跨越，让公众真切看到了AI改变传统工作方式的现实路径。





5.2 OpenClaw光鲜背后的阴影：技术漏洞与生态投毒

OpenClaw的高权限与自主性使其成为网络安全的重灾区。公网暴露导致的实例劫持、技能市场混入的恶意代码，以及任务设计不当引发的Token成本失控，构成了当前"养虾"用户面临的三大核心技术与经济风险。



1. **大规模漏洞暴露与实例劫持：**超4万个未设密码的公网实例被发现，高危漏洞"ClawJacked"能让攻击者仅通过恶意网页就完全控制用户电脑。
2. **技能市场的生态投毒：**ClawHub海量共享Skill中混入大量伪装木马，一旦安装便会窃取用户的API密钥、浏览器记录甚至系统底层密码。
3. **Token成本失控与"账单刺客"：**模型理解偏差或任务设计不当使智能体陷入死循环，重度用户单月消耗数亿Token、产生数千元账单的案例频发。

南京财经大学
NANJING UNIVERSITY OF FINANCE & ECONOMICS

感谢各位垂听：

欢迎批评指正！

NECC

JIANGSU PROVINCIAL KEY LAB. OF E-BUSINESS
JSEB
1999